Proyecto: Los Camachos

El objetivo principal de la empresa elegida, Los Camachos, es incrementar el número de visitantes al parque acuático, por lo que se seleccionó como KPI el número total de visitantes. Este indicador fue seleccionado ya que muestra directamente el objetivo de la empresa. El número total de visitantes se desglosa en la cantidad de visitantes adultos y la cantidad de visitantes niños. Para analizar este KPI, se recopilaron y utilizaron diversas variables, que ya sea directa o indirectamente, afectan y se relacionan con el indicador elegido, y se describen a continuación:

- Fecha: Fecha específica del día.
- Temperatura promedio: Temperatura promedio registrada por día.
- Cantidad adultos: Número de adultos que visitaron el parque por día.
- Cantidad niños: Número de niños que visitaron el parque por día.
- Precio adulto: Precio individual de los boletos para adultos.
- Precio niño: Precio individual de los boletos para niños.
- Total adultos: Ingresos totales por boletos de adulto por día.
- Total niños: Ingresos totales por boletos de niño por día.
- Cantidad familiar: Número de cupones familiares comprados por día.
- Precio familiar: Precio de un cupón familiar, que incluye un paquete de entradas.
- Total familiar: Ingresos totales por cupones familiares por día.
- Cantidad de cupones especiales: Número de cupones especiales comprados por día.
- Precio especial: Precio de un cupón especial, que incluye un descuento o promoción.
- Total especial: Ingresos totales por cupones especiales por día.
- Asistentes totales: Todas las personas que visitaron el parque por día.
- Alimento: Ingresos totales por venta de alimentos dentro del parque por día.
- Extras: Ingresos totales por venta de objetos y servicios adicionales por día.
- Raya: Egresos correspondientes al pago de salarios y compensaciones a los empleados por día.
- Gastos: Otros gastos operativos incurridos por día.
- Neto: El total de ingresos netos por día, calculado como la diferencia entre los ingresos totales y los egresos.

Librerías y Datos

In [1]:
```
import time
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
```

```
import seaborn as sns
import plotly.express as px

from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score
from sklearn.preprocessing import StandardScaler
from sklearn import set_config
from sklearn.metrics import mean_squared_error
import statsmodels.api as sm

from sklearn.cluster import KMeans, DBSCAN
from auto_ts import auto_timeseries
from semopy import Model, Optimizer, semplot
import os
os.environ['PATH'] = '/opt/homebrew/bin:' + os.environ['PATH']

plt.rcParams['figure.figsize'] = (12, 6)
set_config(working_memory=1024)
```

```
Imported auto_timeseries version:0.0.92. Call by using:
model = auto_timeseries(score_type='rmse',
        time_interval='M', non_seasonal_pdq=None, seasonality=False,
        seasonal_period=12, model_type=['best'], verbose=2, dask_xgboost_fla
g=0)
model.fit(traindata, ts_column,target)
model.predict(testdata, model='best')
```

In [2]:
```
start_time = time.perf_counter()
```

In [3]:
```
df = pd.read_excel('Datos.xlsx')
df.head()
```

Out[3]:

	año	mes	fecha	temperatura_promedio	cantidad_adultos	precio_adultos	tota
0	2023	agosto	2023-08-01	22	82	170	
1	2023	agosto	2023-08-02	24	153	170	
2	2023	agosto	2023-08-03	22	98	170	
3	2023	agosto	2023-08-04	21	110	170	
4	2023	agosto	2023-08-05	22	151	170	

5 rows × 23 columns

In [4]:
```
df['ingreso_total'] = df.total_adultos + df.total_niños + df.total_familia +
df['ingreso_entrada'] = df.total_adultos + df.total_niños + df.total_familia
df['asistentes_totales'] = df.cantidad_adultos + df.cantidad_niños + df.cant

df['fecha'] = pd.to_datetime(df['fecha'])
df['día'] = df['fecha'].dt.day_name()

df.head()
```

Out[4]:

	año	mes	fecha	temperatura_promedio	cantidad_adultos	precio_adultos	tota
0	2023	agosto	2023-08-01	22	82	170	
1	2023	agosto	2023-08-02	24	153	170	
2	2023	agosto	2023-08-03	22	98	170	
3	2023	agosto	2023-08-04	21	110	170	
4	2023	agosto	2023-08-05	22	151	170	

5 rows × 27 columns

Cantidad de asistentes

Asistencia por día

In [5]:
```
plt.plot(df.fecha, df.asistentes_totales, c = '#798f9b')
plt.title('Cantidad de visitantes por día')
plt.xlabel('Fecha')
plt.ylabel('Cantidad de visitantes')
plt.grid()
```

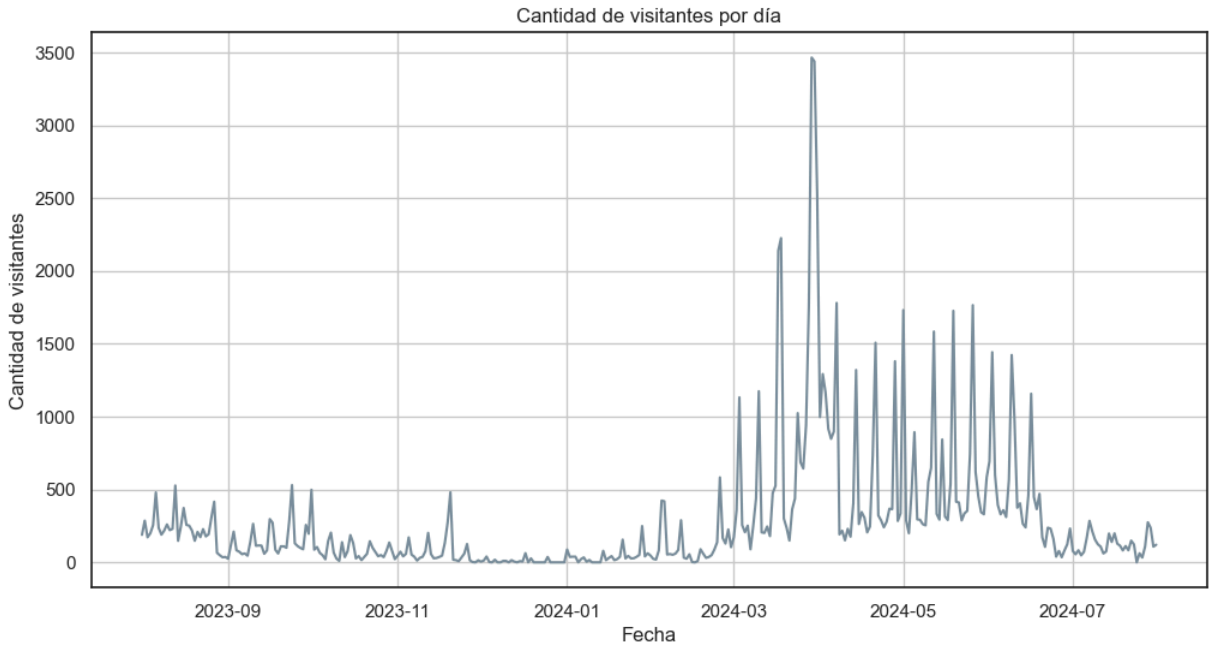

In [6]:
```
order = ['Monday', 'Tuesday', 'Wednesday', 'Thursday', 'Friday', 'Saturday',
df['día'] = pd.Categorical(df['día'], categories=order, ordered=True)
df.groupby('día')['asistentes_totales'].mean().plot(kind='bar', color='#91a8
plt.title('Visitantes promedio por día de la semana')
plt.xlabel('Día')
plt.ylabel('Visitantes promedio')
plt.grid()
```

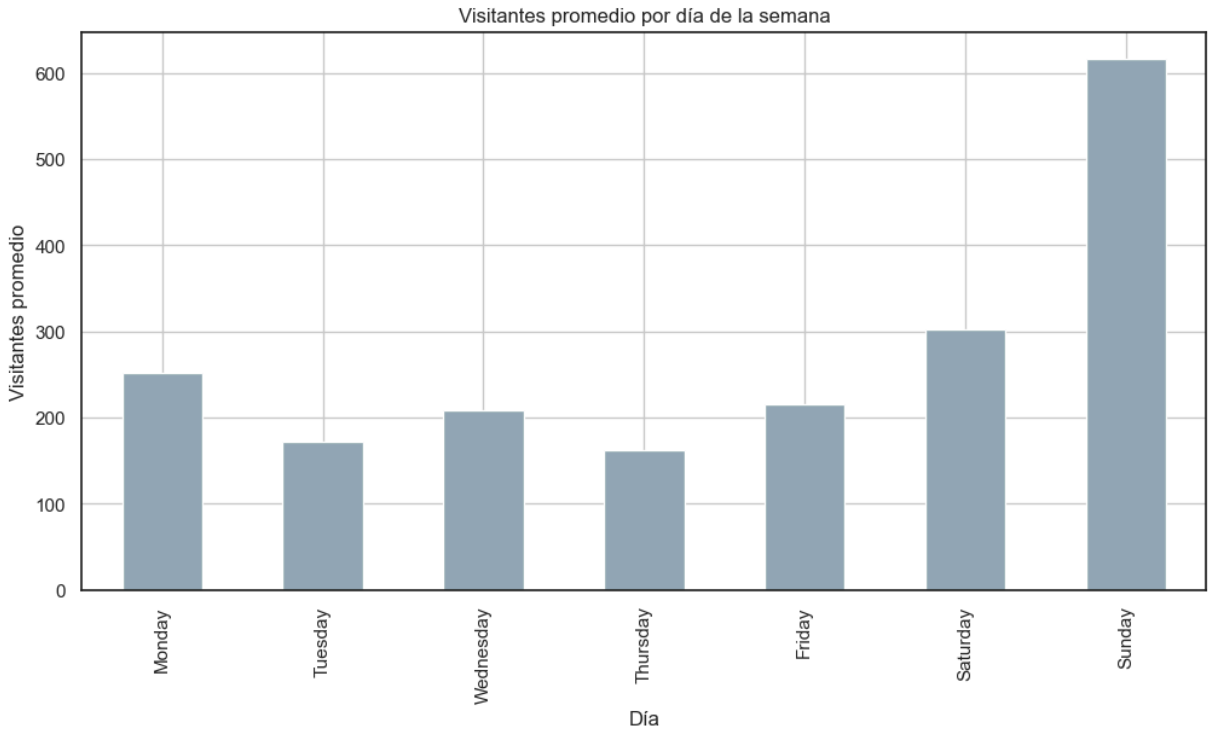

In [7]:
```
plt.plot(df.fecha, df.cantidad_adultos, c = 'navy')
plt.title('Cantidad de adultos a diario')
plt.xlabel('Fecha')
```

```
plt.ylabel('Cantidad de adultos')
plt.grid()
```

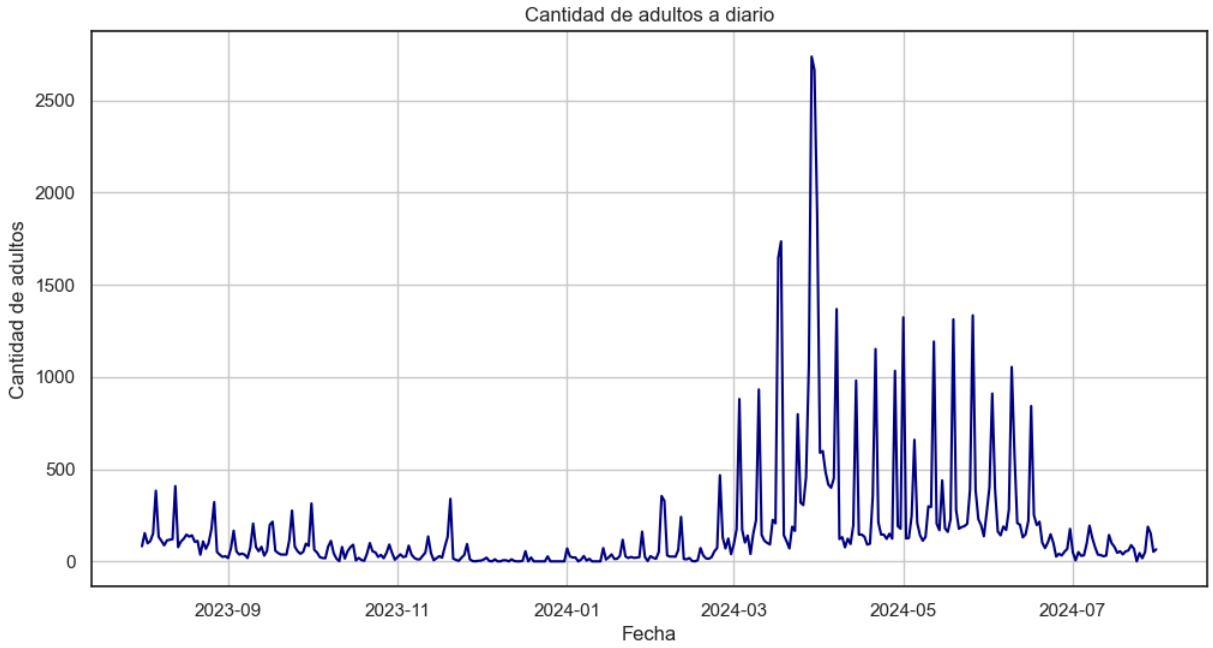

In [8]:
```
plt.plot(df.fecha, df.cantidad_niños, c = 'navy')
plt.title('Cantidad de niños a diario')
plt.xlabel('Fecha')
plt.ylabel('Cantidad de niños')
plt.grid()
```

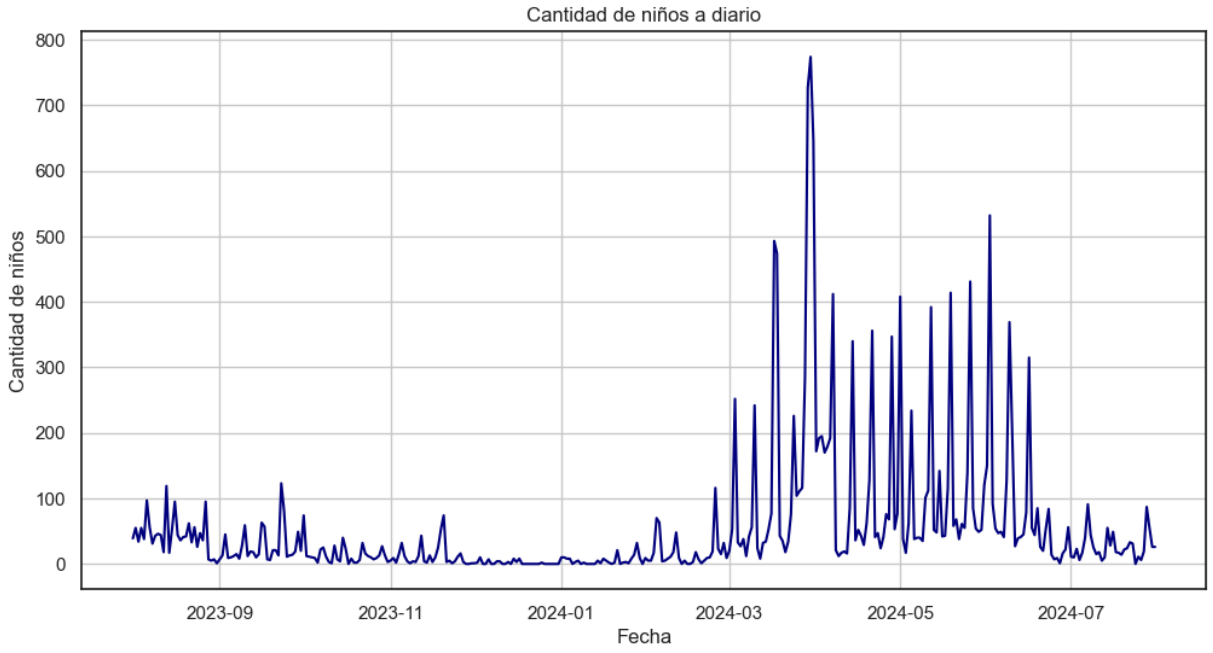

In [9]:
```
plt.plot(df.fecha, df.cantidad_familia, c = 'navy')
plt.title('Cantidad de familias a diario')
plt.xlabel('Fecha')
plt.ylabel('Cantidad de familias')
plt.grid()
```

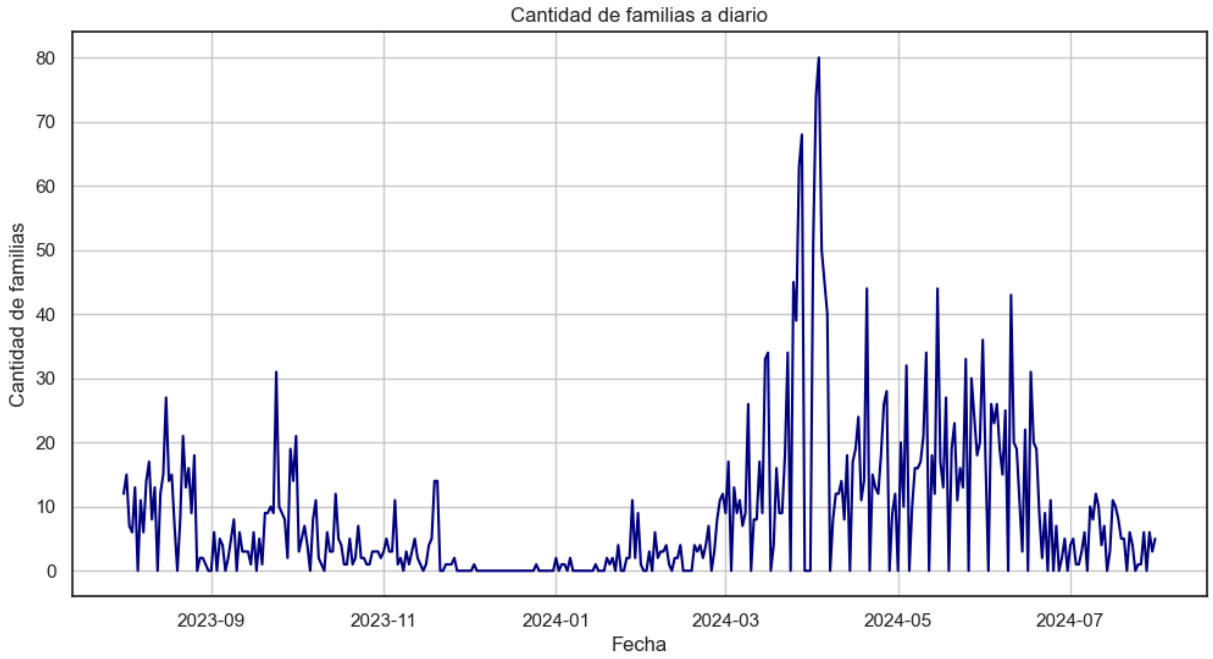

In [10]:
```
plt.plot(df.fecha, df.cantidad_especial, c = 'navy')
plt.title('Cantidad de especiales a diario')
plt.xlabel('Fecha')
plt.ylabel('Cantidad de especiales')
plt.grid()
```

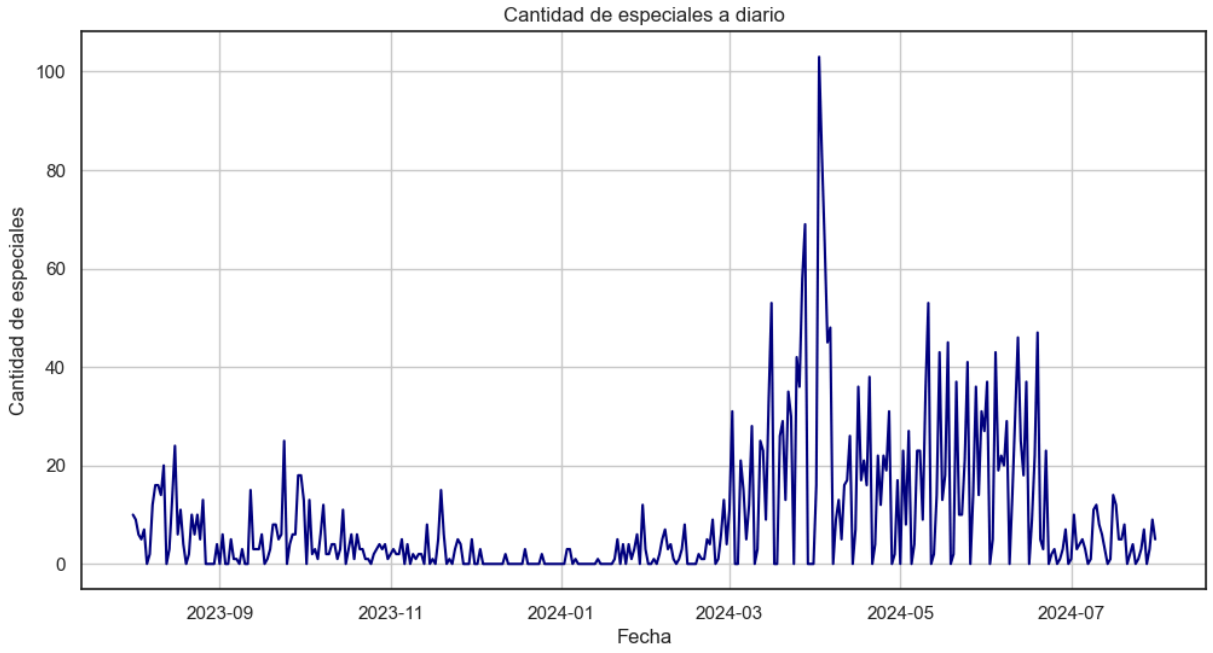

Asistencias promedio diaria por mes

In [72]:
```
df['mes'] = pd.Categorical(df['mes'], categories=[
    'enero', 'febrero', 'marzo', 'abril', 'mayo', 'junio', 'julio', 'agosto'

df.groupby('mes')['asistentes_totales'].mean().plot(kind='bar', color='#5468
plt.title('Cantidad promedio de visitantes diarios por mes')
plt.xlabel('Mes')
```

```
plt.ylabel('Cantidad de visitantes')
plt.grid()
```

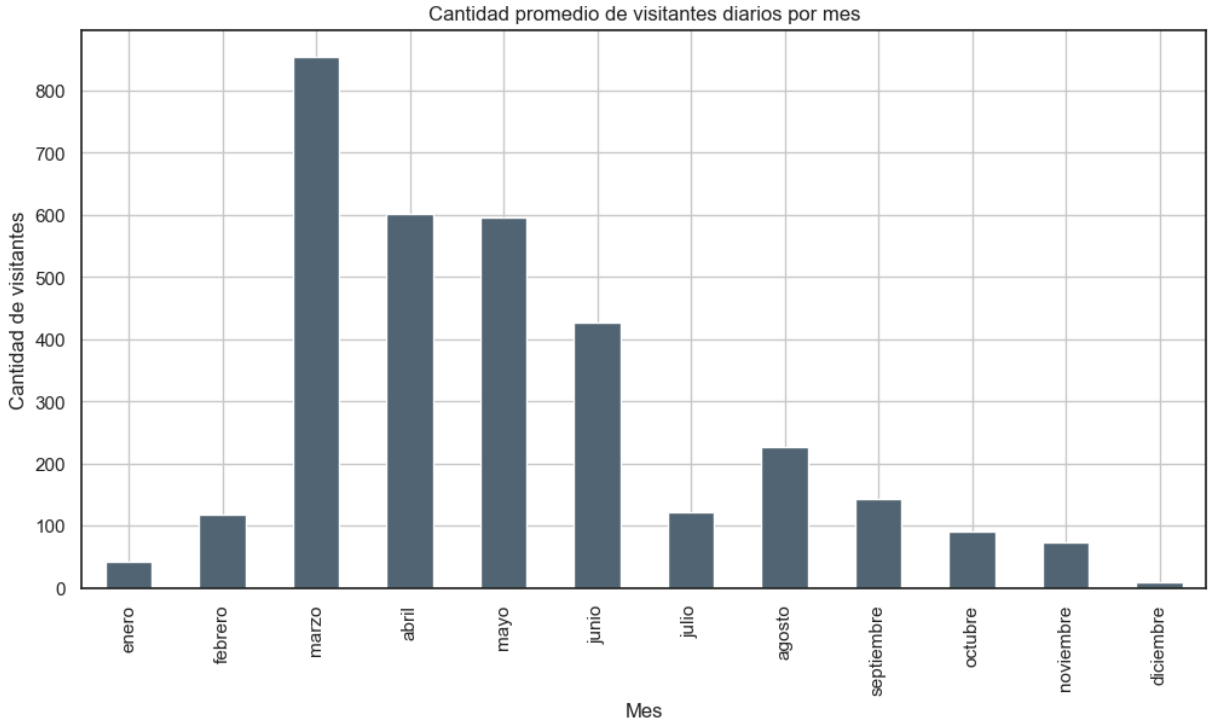

In [12]:
```
df.groupby('mes')['cantidad_adultos'].mean().plot(kind='bar', color='skyblue
plt.title('Cantidad promedio de adultos a diario por mes')
plt.xlabel('Mes')
plt.ylabel('Cantidad de adultos')
plt.grid()
```

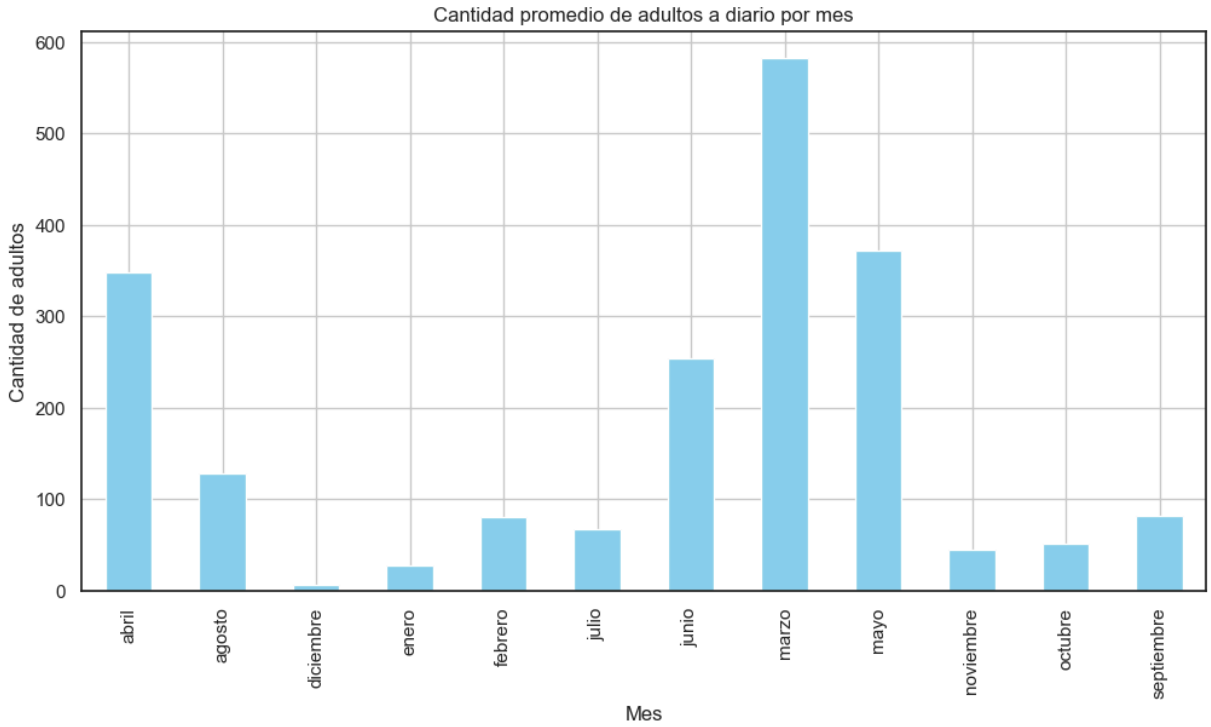

In [13]:
```
df.groupby('mes')['cantidad_niños'].mean().plot(kind='bar', color='skyblue')
plt.title('Cantidad promedio de niños a diario por mes')
```

```
plt.xlabel('Mes')
plt.ylabel('Cantidad de niños')
plt.grid()
```

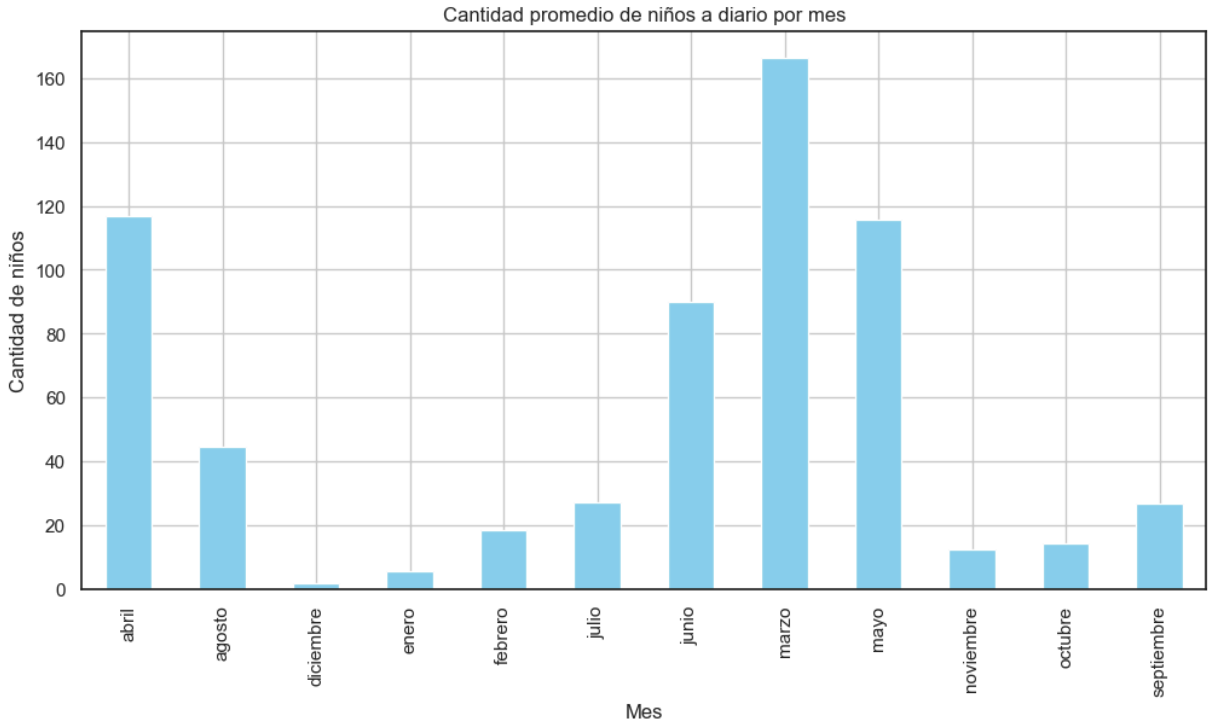

In [14]:
```
df.groupby('mes')['cantidad_familia'].mean().plot(kind='bar', color='skyblue
plt.title('Cantidad promedio de familias a diario por mes')
plt.xlabel('Mes')
plt.ylabel('Cantidad de familias')
plt.grid()
```

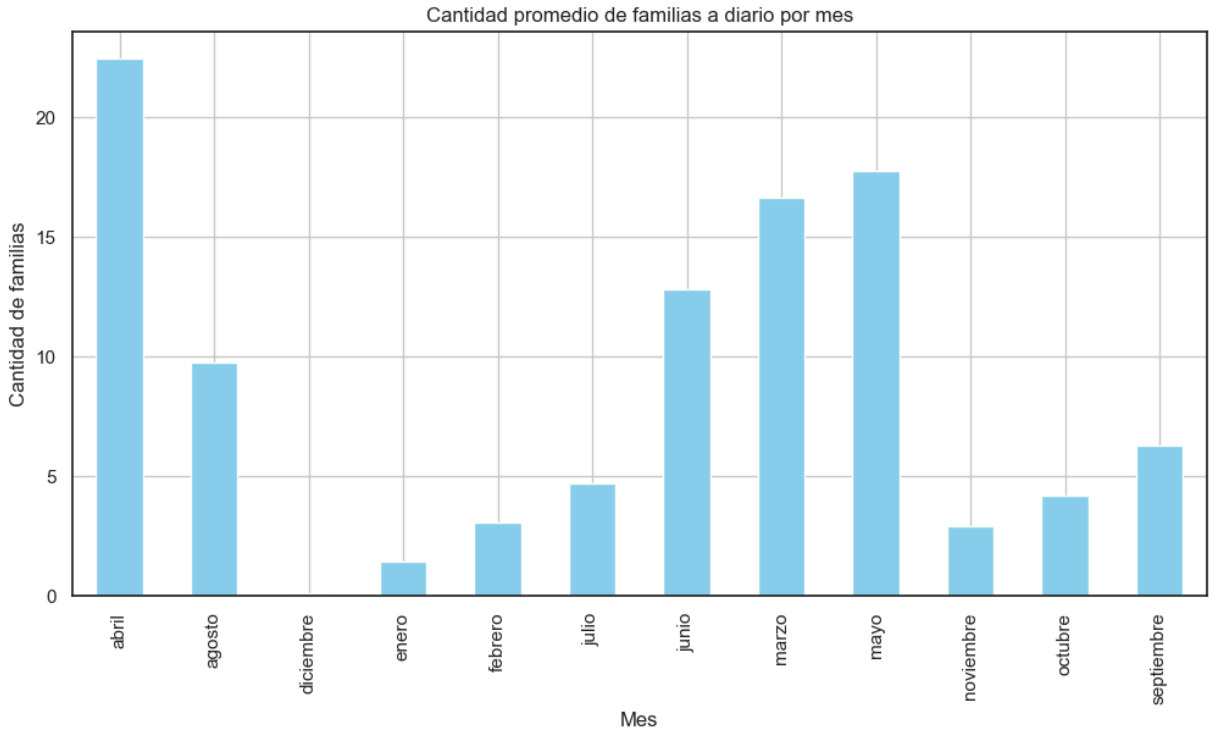

In [15]:
```
df.groupby('mes')['cantidad_especial'].mean().plot(kind='bar', color='skyblu
plt.title('Cantidad promedio de especiales a diario por mes')
plt.xlabel('Mes')
plt.ylabel('Cantidad de especiales')
plt.grid()
```

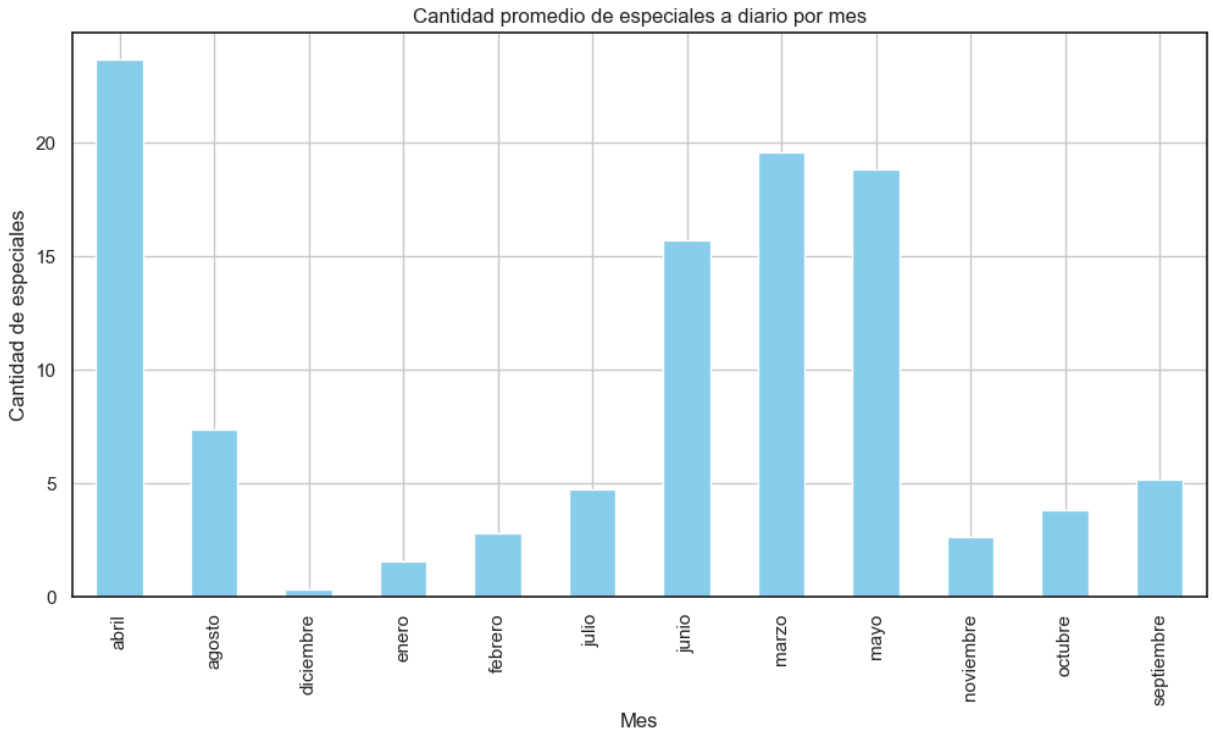

Ingresos

Ingresos por entradas

In [16]:
```
fig = px.line(df, x='fecha', y='ingreso_entrada', title='Ingreso por entrada
fig.update_layout(
    width=1200,
    height=600
)
fig.update_traces(line=dict(color='navy'))
fig.show()
```

In [17]:
```
df.groupby('mes')['ingreso_entrada','alimento','extras'].mean().plot(kind='b
plt.title('Comparación de ingreso diario por mes')
plt.xlabel('Mes')
plt.ylabel('Ingreso')
plt.grid()
```

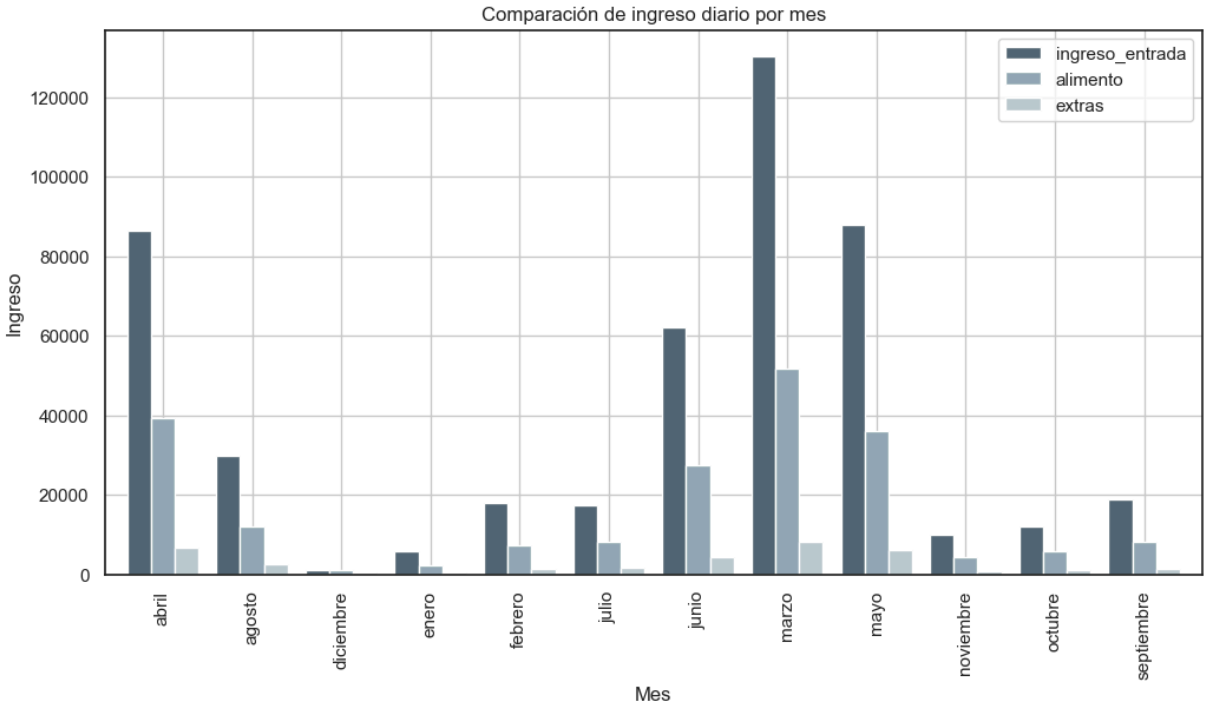

In [18]:
```
df.groupby('mes')['ingreso_entrada'].mean().plot(kind='bar', color=['skyblue
plt.title('Ingreso promedio por entradas y alimentos a diario por mes')
plt.xlabel('Mes')
plt.ylabel('Ingreso')
plt.grid()
```

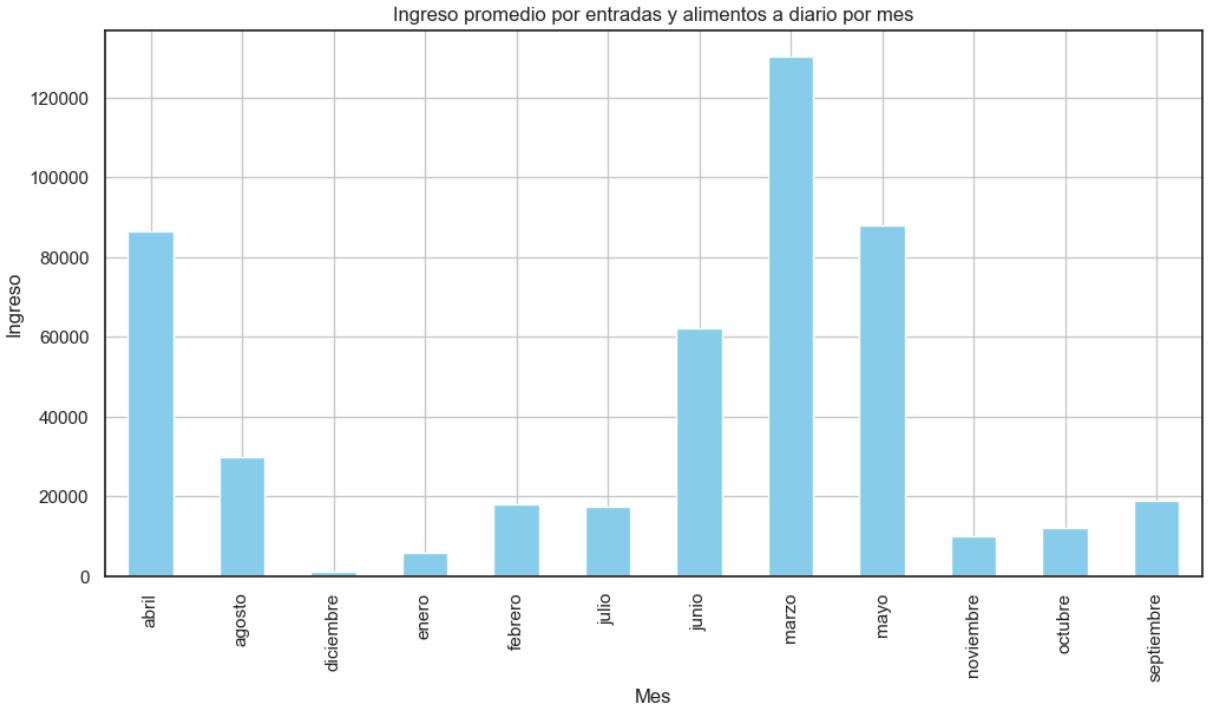

In [19]:
```
df.groupby('día')['ingreso_entrada'].mean().plot(kind='bar', color='skyblue'
plt.title('Ingreso promedio por entradas por día')
plt.xlabel('Día')
plt.ylabel('Ingreso')
plt.grid()
```

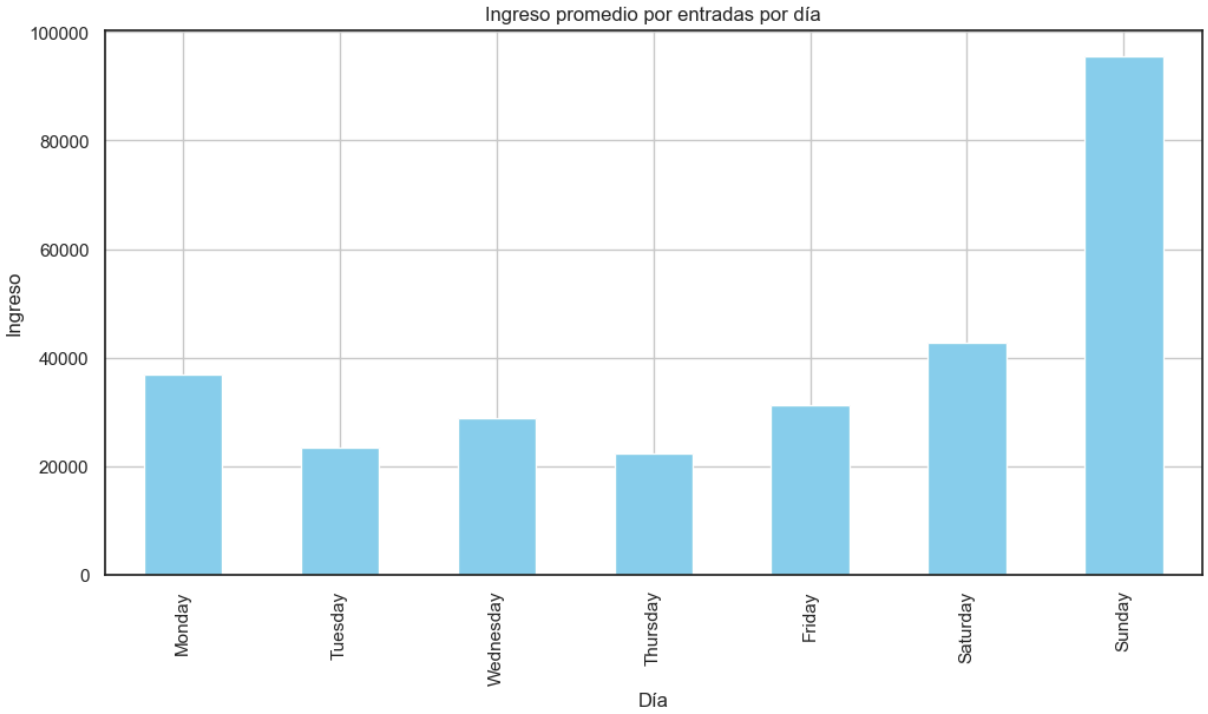

Ingreso por alimentos

In [20]:
```
fig = px.line(df, x='fecha', y='alimento', title='Ingreso por comida a diari
fig.update_layout(
    width=1200,
    height=600
)
fig.update_traces(line=dict(color='navy'))
fig.show()
```

In [21]:
```
df.groupby('mes')['alimento'].mean().plot(kind='bar', color='skyblue')
plt.title('Ingreso promedio por alimentos a diario por mes')
plt.xlabel('Mes')
plt.ylabel('Ingreso')
plt.grid()
```

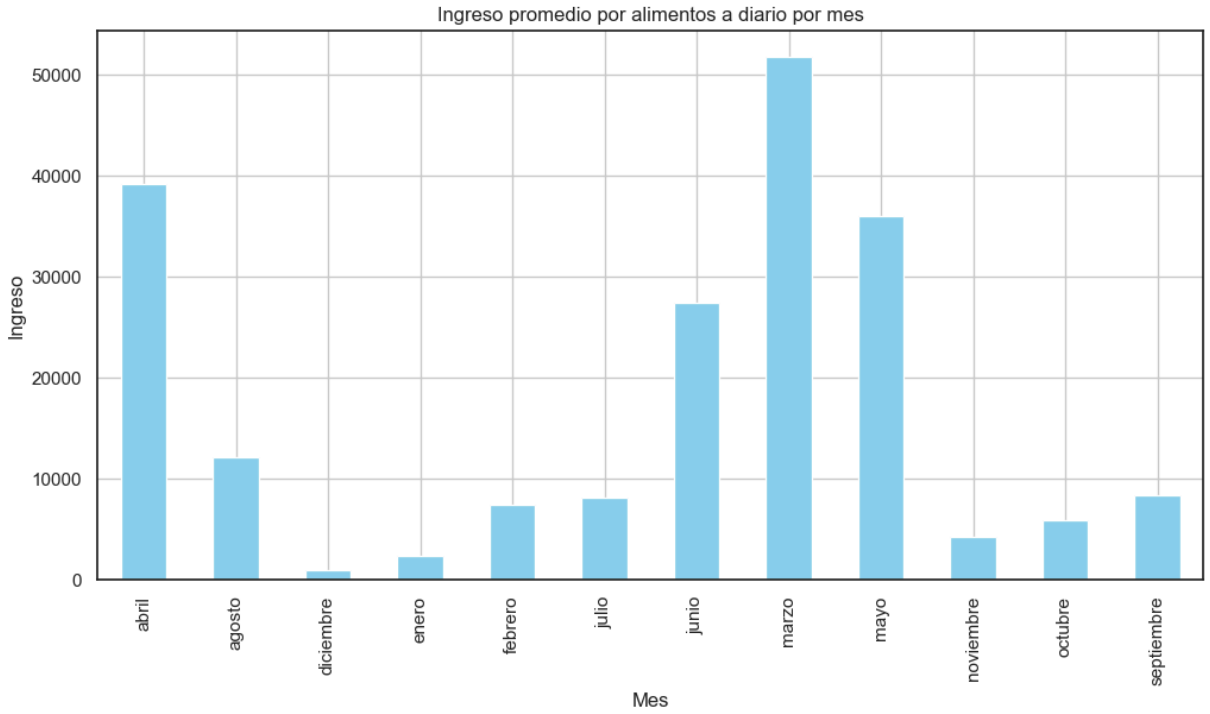

In [22]:
```
df.groupby('día')['alimento'].mean().plot(kind='bar', color='skyblue')
plt.title('Ingreso promedio por alimentos por día')
plt.xlabel('Día')
plt.ylabel('Ingreso')
plt.grid()
```

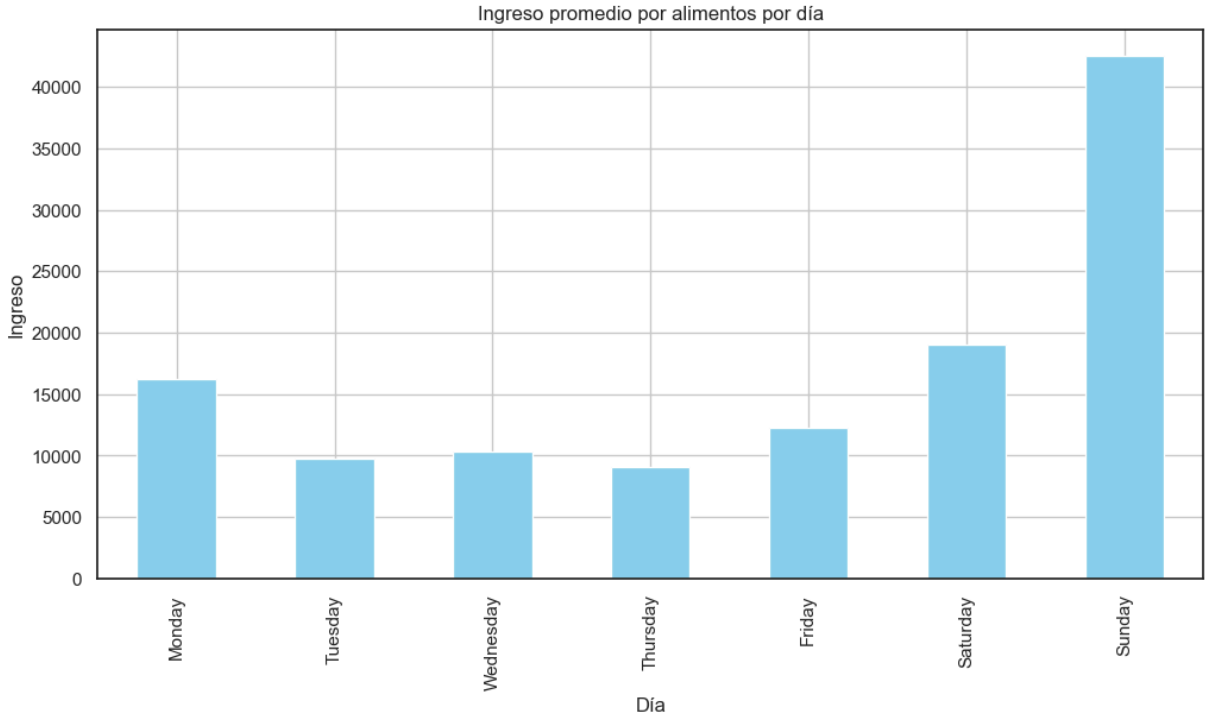

Ingresos totales

In [23]:
```
fig = px.line(df, x='fecha', y='ingreso_total', title='Ingreso total a diari
fig.update_layout(
```

```
    width=1200,
    height=600
)
fig.update_traces(line=dict(color='navy'))
fig.show()
```

In [24]:
```
df['mes'] = pd.Categorical(df['mes'], categories=[
    'enero', 'febrero', 'marzo', 'abril', 'mayo', 'junio', 'julio', 'agosto'
df.groupby('mes')['ingreso_total'].mean().plot(kind='bar', color='#bccbce')
plt.title('Ingreso total promedio diario por mes')
plt.xlabel('Mes')
plt.ylabel('Ingreso')
plt.grid()
```

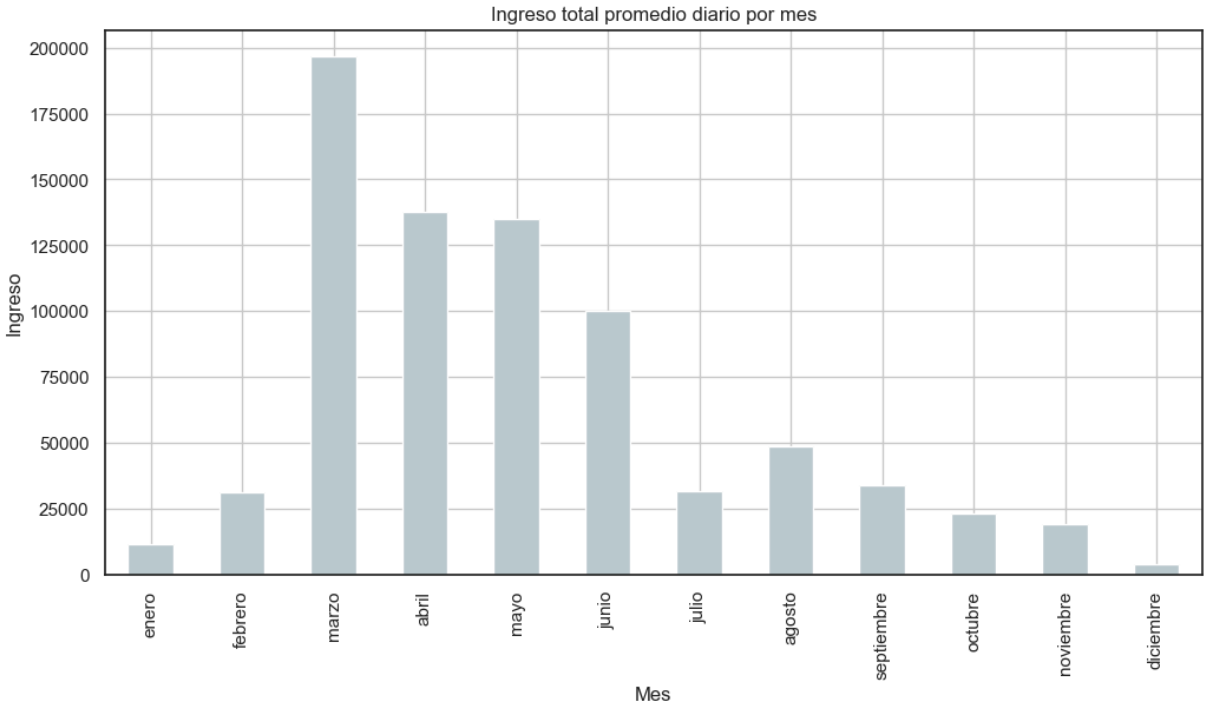

In [25]:
```
df.groupby('día')['ingreso_total'].mean().plot(kind='bar', color='skyblue')
plt.title('Ingreso total promedio por día')
plt.xlabel('Día')
plt.ylabel('Ingreso')
plt.grid()
```

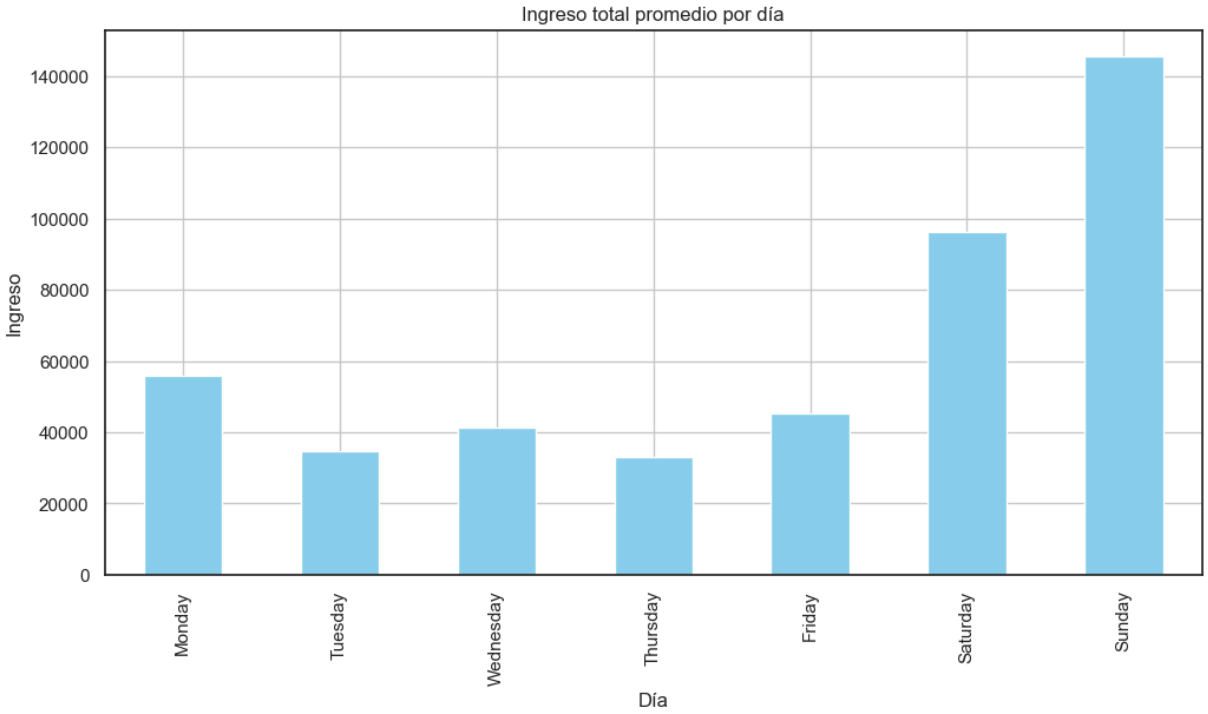

Neto

In [26]:
```
fig = px.line(df, x='fecha', y='neto', title='Neto diario')
fig.update_layout(
    width=1200,
    height=600
)
fig.update_traces(line=dict(color='navy'))
fig.show()
```

In [27]:
```
df.groupby('mes')['neto'].mean().plot(kind='bar', color='skyblue')
plt.title('Neto promedio a diario por mes')
plt.xlabel('Mes')
plt.ylabel('Neto')
plt.grid()
```

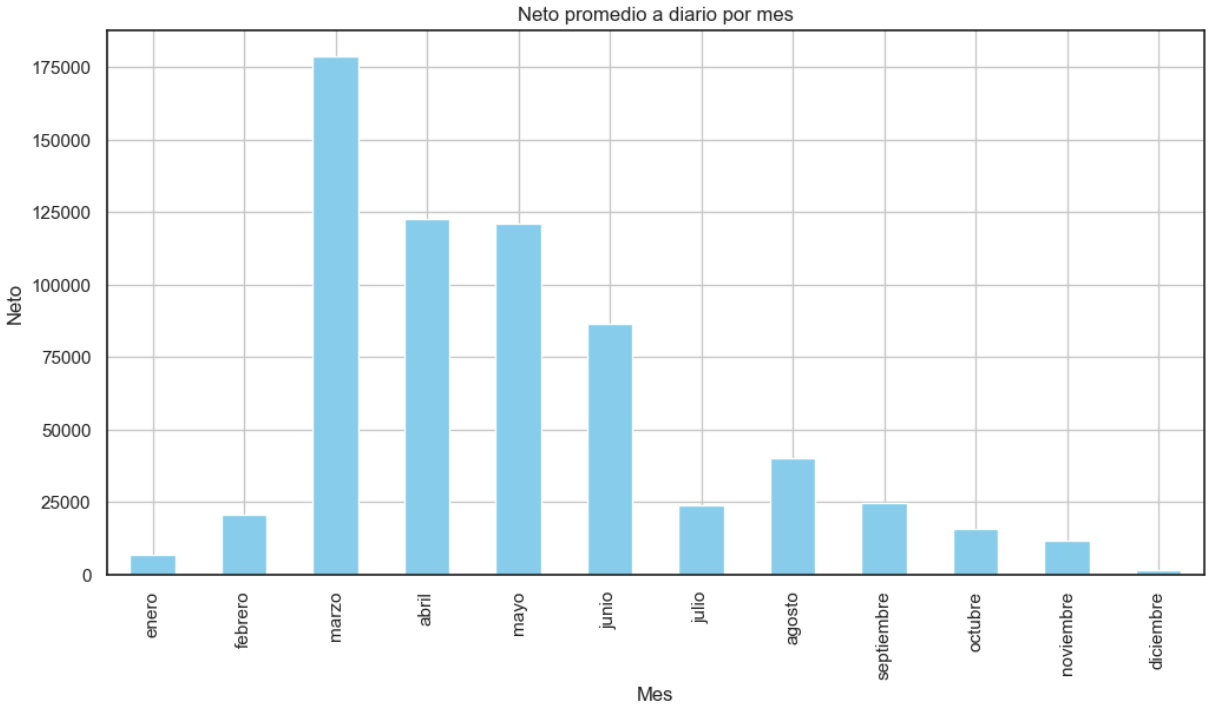

In [28]:
```
df.groupby('día')['neto'].mean().plot(kind='bar', color='skyblue')
plt.title('Neto promedio por día')
plt.xlabel('Día')
plt.ylabel('Neto')
plt.grid()
```

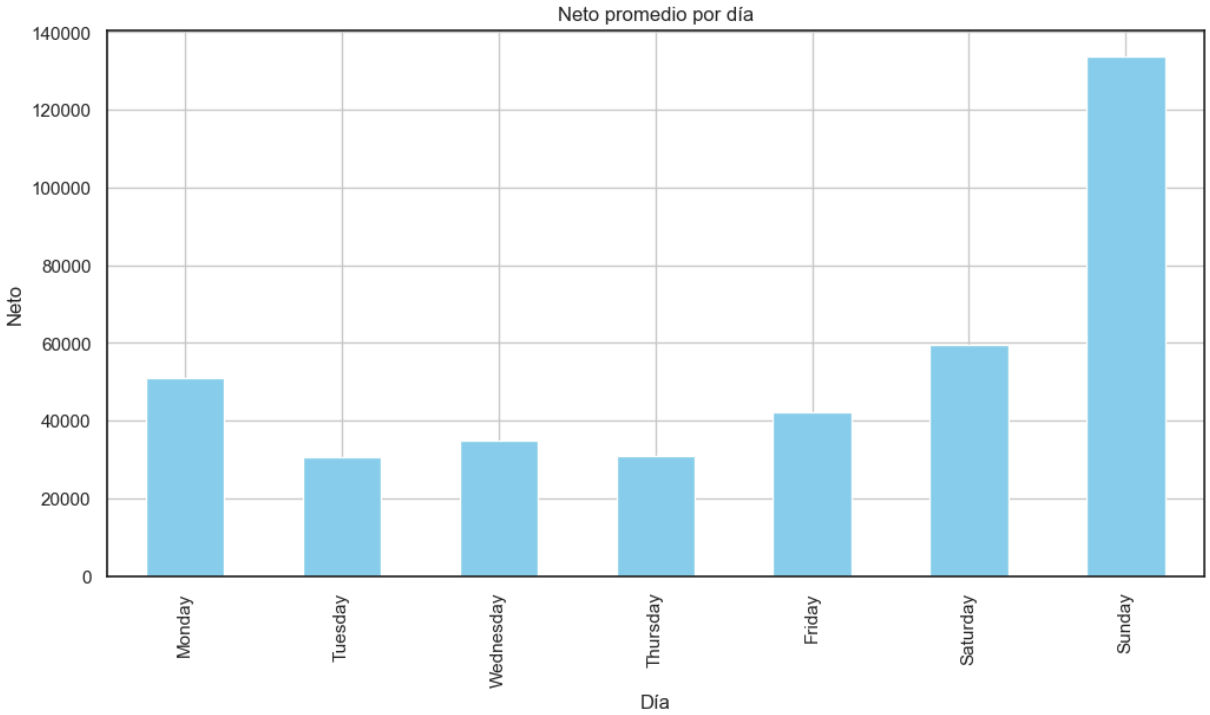

Separación

Ingreso total

In [29]:
```
wknd = df.query("día == 'Friday' or día == 'Saturday' or día == 'Sunday'")
wd = df.query("día == 'Monday' or día == 'Tuesday' or día == 'Wednesday' or

wknd.groupby('mes')['ingreso_total'].mean().plot(kind='bar', color='skyblue'
plt.title('Ingreso total promedio a diario en fin de semana por mes')
plt.xlabel('Mes')
plt.ylabel('Ingreso')
plt.grid()
```

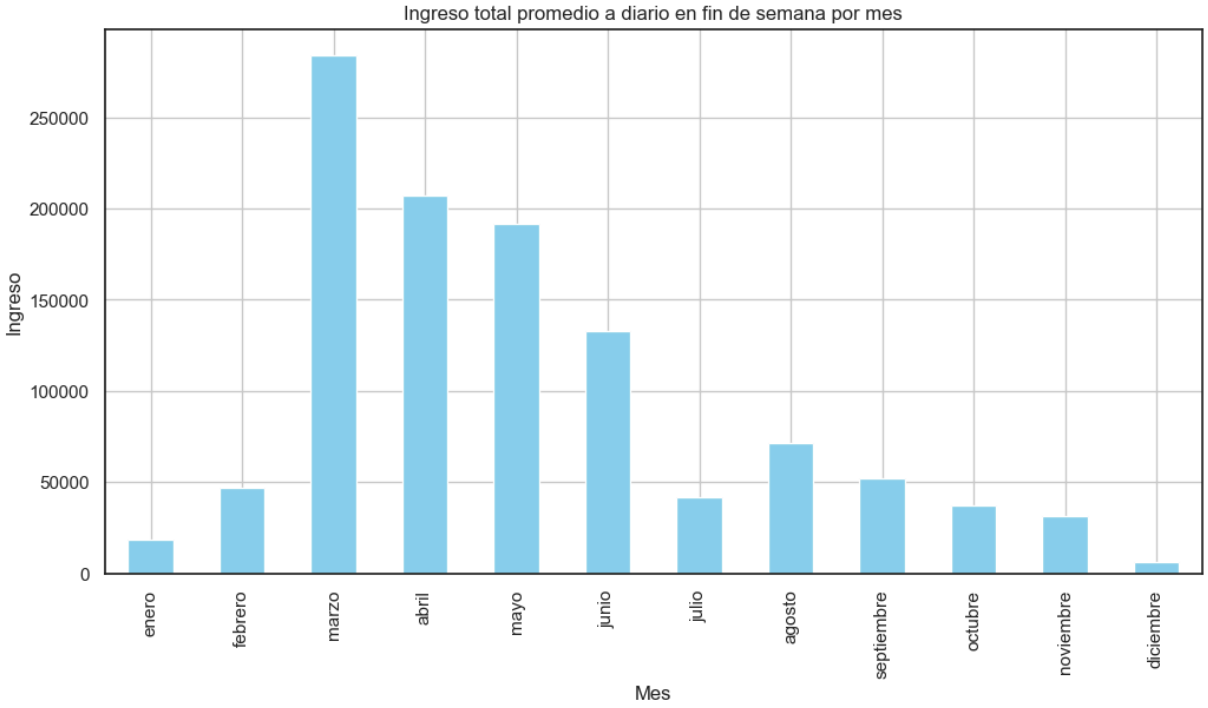

In [30]:
```
wd.groupby('mes')['ingreso_total'].mean().plot(kind='bar', color='skyblue')
plt.title('Ingreso total promedio a diario entre semana por mes')
plt.xlabel('Mes')
plt.ylabel('Ingreso')
plt.grid()
```

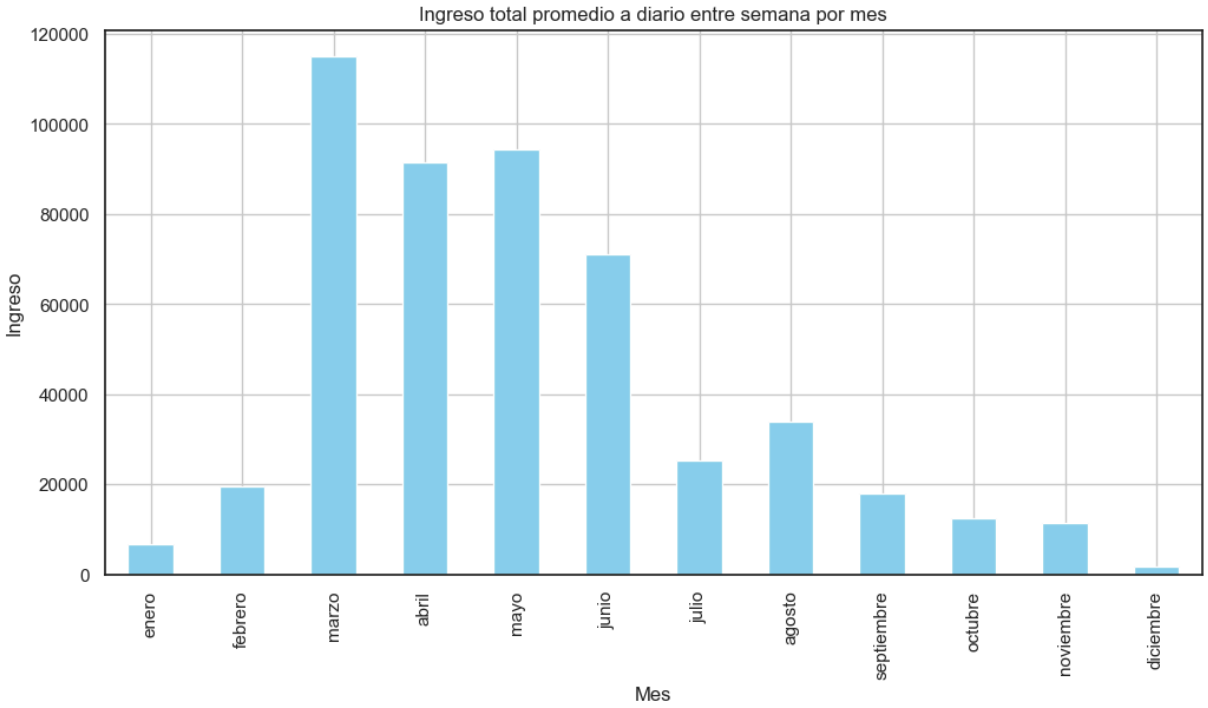

Asistencia total

In [31]:
```
wknd.groupby('mes')['asistentes_totales'].mean().plot(kind='bar', color='sky
plt.title('Asistencia promedio a diario en fin de semana por mes')
plt.xlabel('Mes')
plt.ylabel('Ingreso')
plt.grid()
```

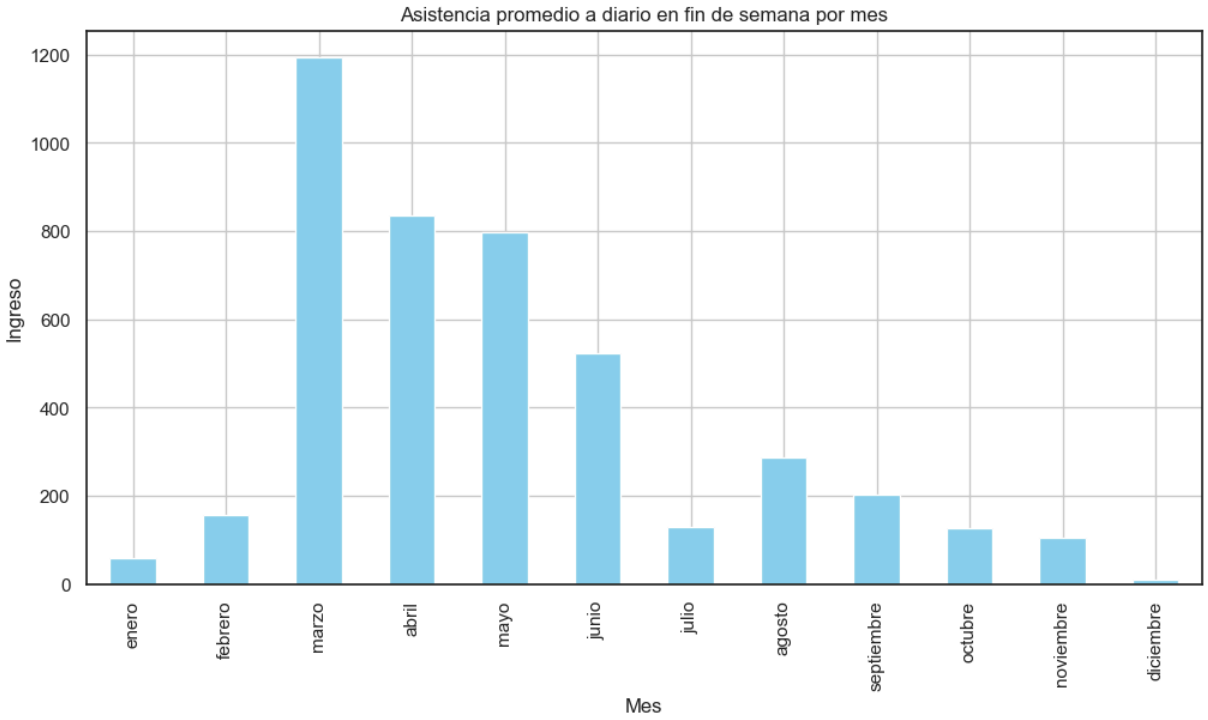

In [32]:
```
wd.groupby('mes')['asistentes_totales'].mean().plot(kind='bar', color='skybl
plt.title('Asistencia promedio a diario entre semana por mes')
```

```
plt.xlabel('Mes')
plt.ylabel('Ingreso')
plt.grid()
```

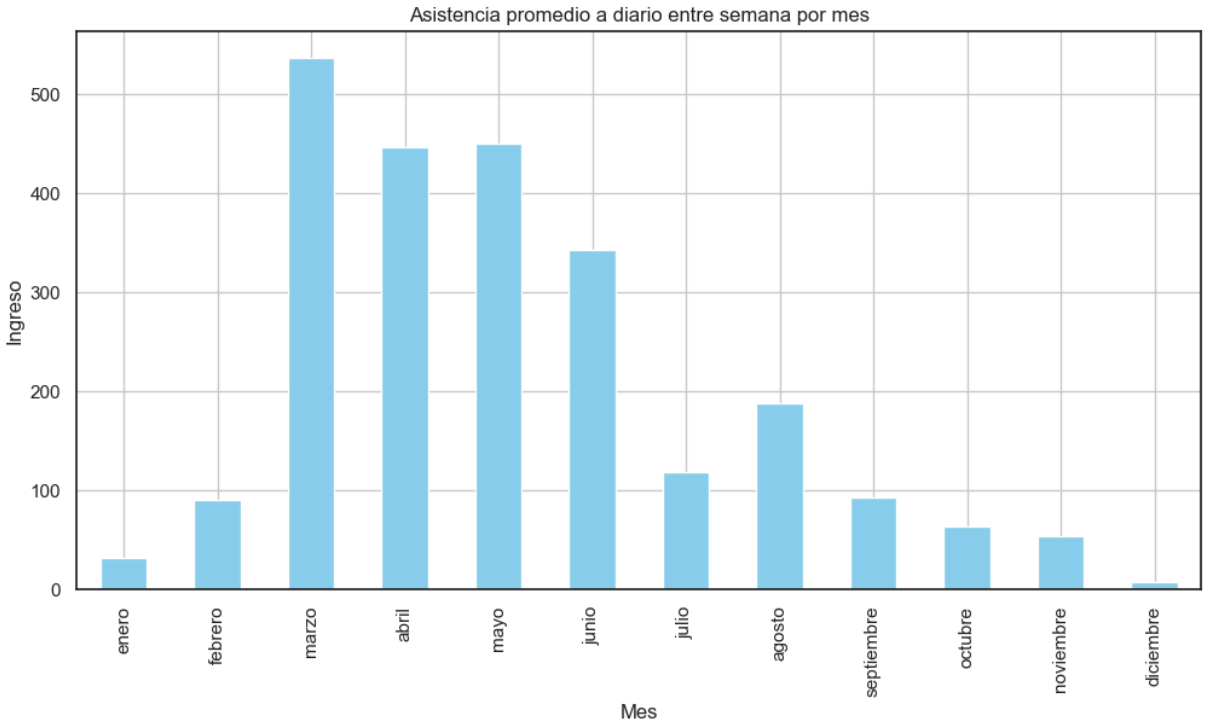

Correlación

In [33]:
```
df_trend = df[['temperatura_promedio','asistentes_totales']]
```

In [34]:
```
x_trend = df_trend['temperatura_promedio']
y_trend = df_trend['asistentes_totales']

X = x_trend.values.reshape(-1, 1)  # Reshape para hacerlo bidimensional
y = y_trend

model = LinearRegression().fit(X, y)
model.intercept_ ,model.coef_[0]

y_pred = model.predict(X)

df_trend['y_pred'] = y_pred
```

In [35]:
```
sns.scatterplot(x = df_trend.temperatura_promedio, y = df_trend.asistentes_t
plt.plot(df_trend.temperatura_promedio, df_trend.y_pred, c = '#546873')
plt.title('Asistencia vs Temperatura promedio')
plt.xlabel('Temperatura promedio')
plt.ylabel('Asistencia')
plt.grid()
plt.show()
```

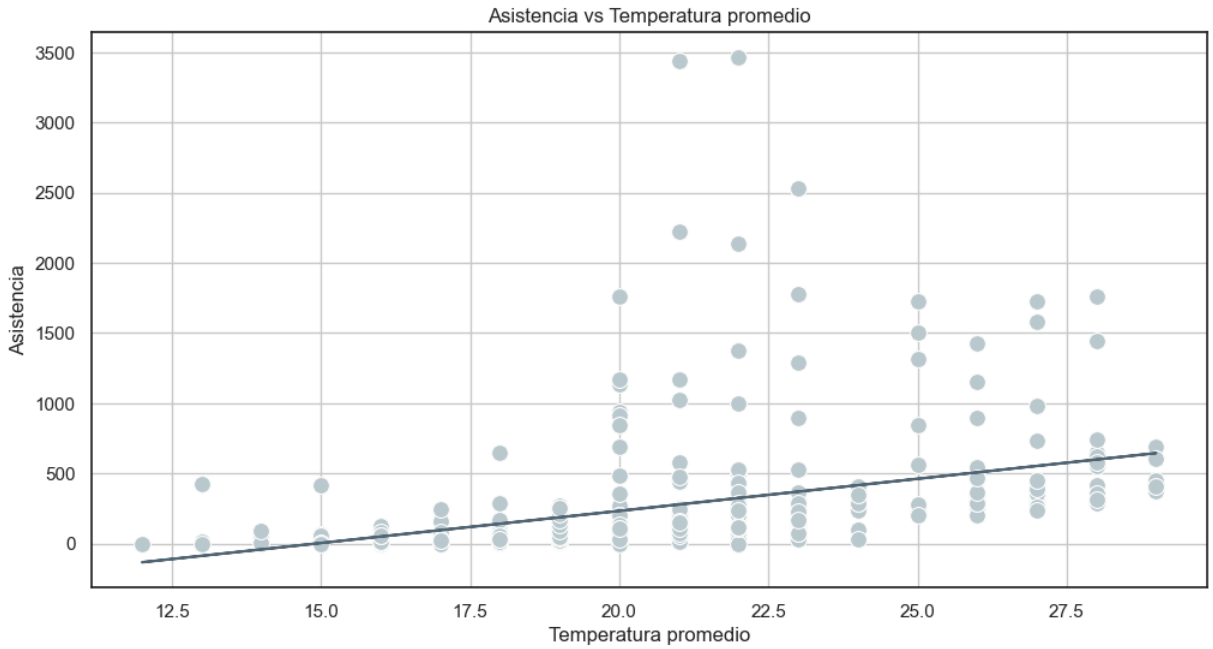

In [36]:
```
df[['temperatura_promedio', 'asistentes_totales']].corr()
```

Out[36]:

	temperatura_promedio	asistentes_totales
temperatura_promedio	1.000000	0.375123
asistentes_totales	0.375123	1.000000

Clusters

Estandarización de datos

In [37]:
```
# Separar variables numéricas y categóricas
numerical_features = ['ingreso_total','temperatura_promedio']
categorical_features = []

# Hacer las categóricas dummies
#encoded_features = pd.get_dummies(df[categorical_features],
               #columns=categorical_features,
               #drop_first=True)

# Estandarizar variables numéricas
data_to_model_standarized = StandardScaler().fit_transform(df[numerical_feat

# Hacer dataframe variables numéricas
data_to_model_df = pd.DataFrame(data_to_model_standarized,
                                columns=numerical_features)

# Acomodar variables categóricas
#encoded_features_df = encoded_features.reset_index()

# Juntar ambas variables
#data_to_model = data_to_model_df.merge(encoded_features_df, on='index')
```

```
#data_to_model = data_to_model.drop('index', axis=1)
data_to_model_df
```

Out[37]:

	ingreso_total	temperatura_promedio
0	-0.312582	0.293673
1	-0.108444	0.842061
2	-0.288119	0.293673
3	-0.266885	0.019478
4	0.166950	0.293673
...	...	...
361	-0.051567	-0.254716
362	-0.041669	0.293673
363	-0.156688	0.293673
364	-0.395866	0.293673
365	-0.385249	0.293673

366 rows × 2 columns

Número óptimo de clusters

In [38]:

```
# Determinar el número óptimo de clusters usando el método del codo
sum_of_squared_distances = []
K = range(1, 15)  # Ajuste el rango según sea necesario
for k in K:
    km = KMeans(n_clusters=k, random_state=42)
    km = km.fit(data_to_model_df)
    sum_of_squared_distances.append(km.inertia_)

# Plot the Elbow curve
plt.figure(figsize=(10, 6))
plt.plot(K, sum_of_squared_distances, 'bx-')
plt.xlabel('Number of clusters (k)')
plt.ylabel('Sum of Squared Distances')
plt.title('Elbow Method For Optimal k')
plt.show()
```

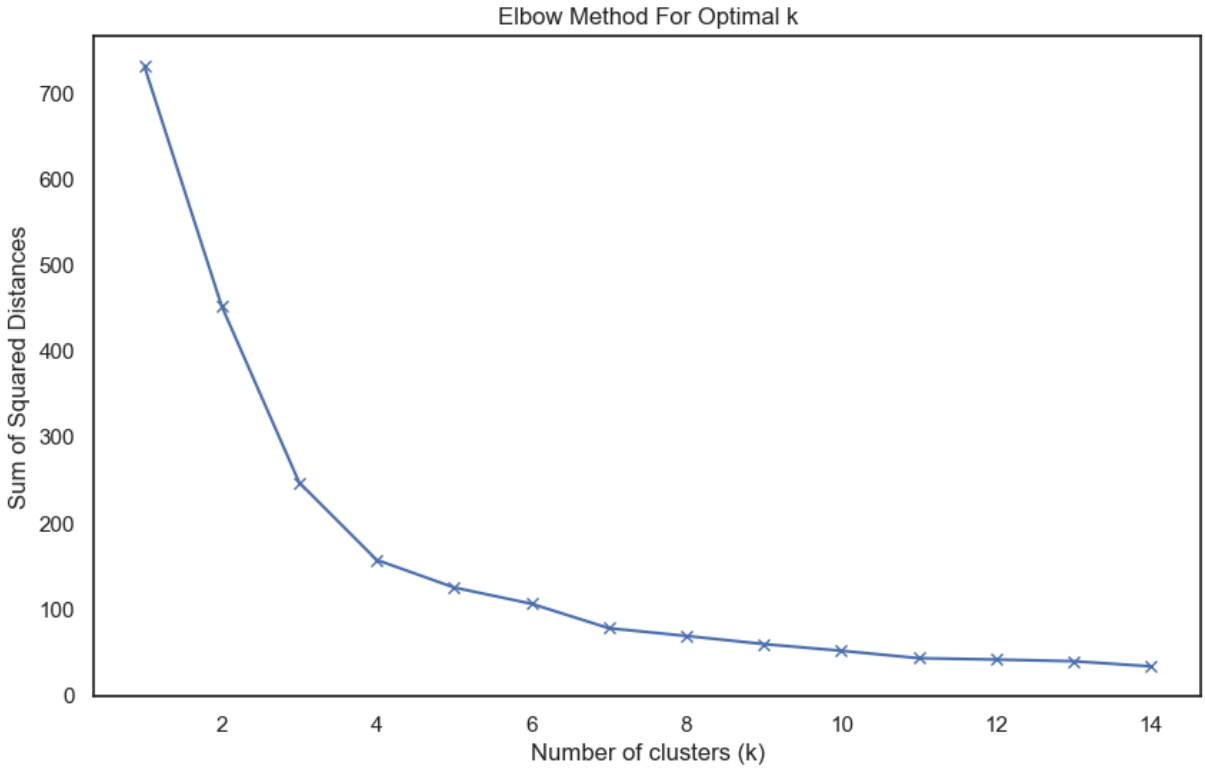

In [39]:
```
# Aplicar K-means clustering para identificar segmentos de clientes
kmeans = KMeans(n_clusters=4, random_state=42)
labels = kmeans.fit_predict(data_to_model_df)

# Agregar las etiquetas del cluster al DataFrame original para análisis
data_to_model_df['Cluster'] = labels
df['Cluster'] = labels
```

Visualización de clusters

In [40]:
```
def boxplot_clusters(columns):
    for col in columns:
        plt.figure(figsize=(5, 5))
        sns.boxplot(x='Cluster', y=col, data=df, hue='Cluster', palette=['#5
        plt.title(f'Boxplot de {col} por Clusters')
        plt.show()
```

In [41]:
```
boxplot_clusters(numerical_features)
```

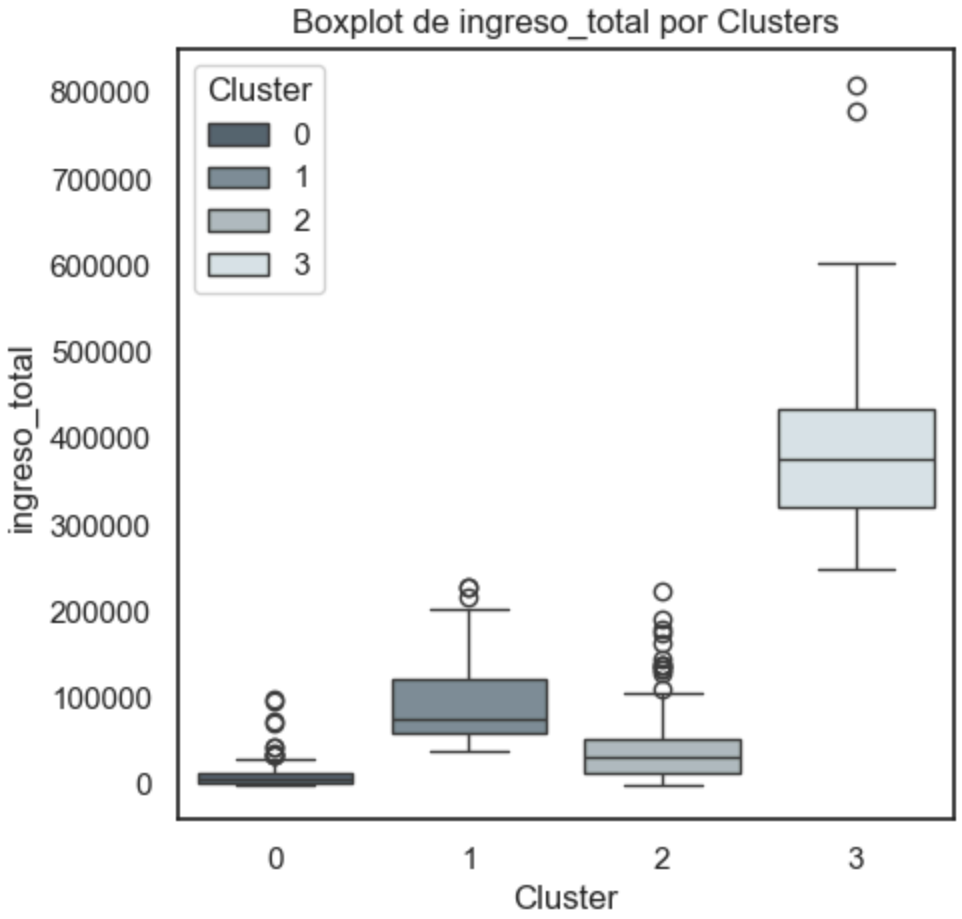
Boxplot de ingreso_total por Clusters
Cluster
0
1
2
3
ingreso_total
800000
700000
600000
500000
400000
300000
200000
100000
0
0
1
2
3
Cluster

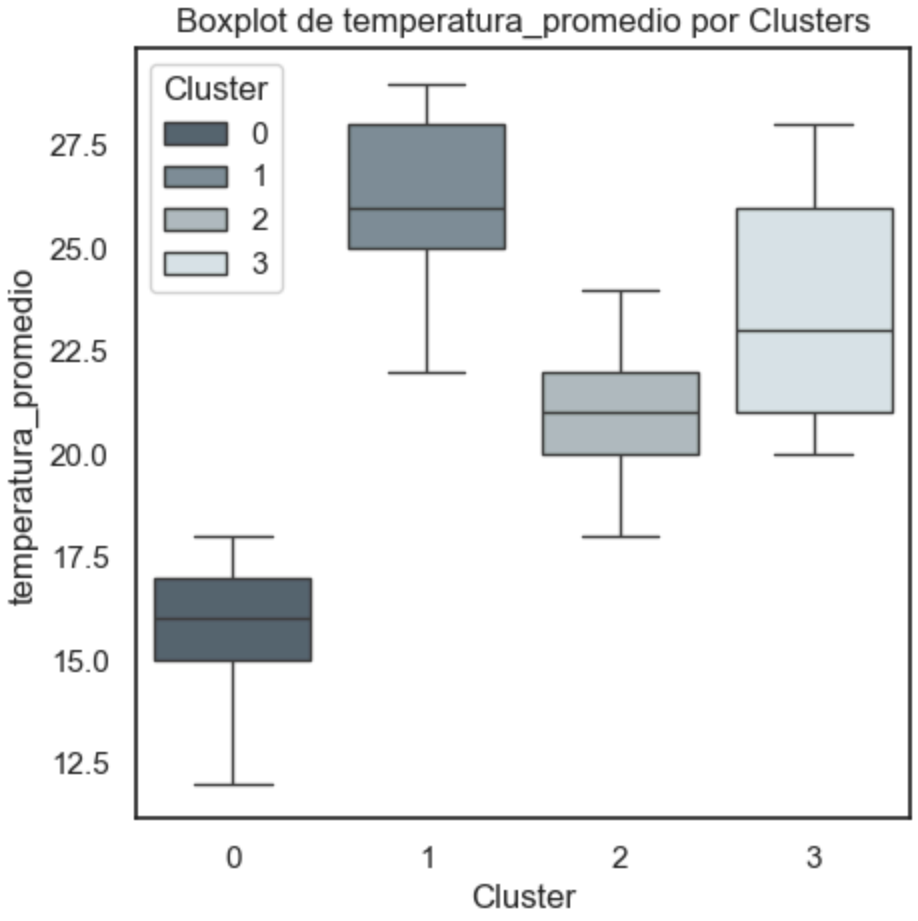
Boxplot de temperatura_promedio por Clusters
Cluster
0
1
2
3
temperatura_promedio
27.5
25.0
22.5
20.0
17.5
15.0
12.5
0
1
2
3
Cluster

Análisis de clusters

El rango de temperatura en el que se tiene la mayor cantidad de ingresos es apróximadamente de 21 a 26 grados Celsius. Si la temperatura sube o baja de este rango, los ingresos se ven reducidos. En este rango, los ingresos diarios del clúster se encuentran entre 320,000 y 450,000 pesos. Si la tempreratura sube de 26 grados, los ingresos bajan al rango de 80,000 a 120,000 pesos. El rango de temperaturas más bajas, que oscila entre los 15 a los 16.5 grados presenta los menores ingresos de todo el año.

Regresión lineal

Dummies arbitrarias

In [42]:
```
df['is_wknd'] = df['día'].isin(['Friday', 'Saturday', 'Sunday'])
df['is_hs'] = df['mes'].isin(['marzo', 'abril', 'mayo'])

columns_from_education = df.loc[:, 'is_wknd':].select_dtypes(include='bool')
df[columns_from_education] = df[columns_from_education].astype(int)
```

In [43]:
```
X = df[['temperatura_promedio','is_wknd','is_hs']]
y = df['asistentes_totales']
```

In [44]:
```
# Agregar la constante (intercepto) a las variables independientes
X = sm.add_constant(X)

# Ajustar el modelo usando OLS
model = sm.OLS(y, X)
results = model.fit()

# Mostrar el resumen del modelo
print(results.summary())
```

```
                            OLS Regression Results
==============================================================================
==
Dep. Variable:     asistentes_totales   R-squared:                       0.3
48
Model:                            OLS   Adj. R-squared:                  0.3
43
Method:                 Least Squares   F-statistic:                     64.
39
Date:                Mon, 25 Nov 2024   Prob (F-statistic):           2.19e-
33
Time:                        11:14:46   Log-Likelihood:                -267
2.9
No. Observations:                 366   AIC:                             535
4.
Df Residuals:                     362   BIC:                             536
9.
Df Model:                           3
Covariance Type:            nonrobust
==============================================================================
============
                            coef    std err          t      P>|t|      [0.025
0.975]
------------------------------------------------------------------------------
------------
const                  -372.1470    119.040     -3.126      0.002    -606.243
-138.051
temperatura_promedio    21.7387      5.777      3.763      0.000      10.378
33.099
is_wknd                178.5335     38.196      4.674      0.000     103.420
253.647
is_hs                  464.1459     48.562      9.558      0.000     368.647
559.645
==============================================================================
==
Omnibus:                      314.549   Durbin-Watson:                   0.9
25
Prob(Omnibus):                  0.000   Jarque-Bera (JB):             7005.5
04
Skew:                           3.554   Prob(JB):                         0.
00
Kurtosis:                      23.220   Cond. No.                         13
6.
==============================================================================
==

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is corre
ctly specified.
```

Hacemos una regresión lineal para predecir la cantidad de personas que asistirán al parque segun ciertas características y se oobtiene los siguiente:

- Temperatura promedio: Por cada unidad que se mueva la temperatura promedio del día afecta 21.7387 a la cantidad de personas.

- is_wknd: Esto significa que si es fin de semana se esperan 178.5335 personas.
- is_hs: Si es temporada alta (marzo, abril o mayo) se esperan 464.1459 personas.

El modelo tiene una R^2 de 0.348, por lo que explica muy poca variación de los datos pero también tiene un F-estadístico muy bajo lo que significa que al menos una de las variables impacta significativamente a la cantidad de asistentes.

In [45]:
```
new_day_data = {
    'const': [1],
    'temperatura_promedio': [27],
    'is_wknd': [1],
    'is_hs': [1]
}

new_day_data = pd.DataFrame(new_day_data)

asistentes_predecidos = results.predict(new_day_data)

print(f"Asistentes predecidos del nuevo día: {asistentes_predecidos[0]:,.2f}
```

```
Asistentes predecidos del nuevo día: 857.48
```

Dummies de código

In [46]:
```
categorical_features = ['mes','día']
numerical_features = ['temperatura_promedio']

data_encoded = pd.get_dummies(df[['asistentes_totales'] + categorical_featur

data_encoded['temperatura_promedio'] = df['temperatura_promedio']

df_to_model = data_encoded
```

In [47]:
```
X1 = df_to_model[['temperatura_promedio','mes_marzo','mes_abril','mes_mayo',
                  'día_Sunday']]
y1 = df_to_model['asistentes_totales']
```

In [48]:
```
# Agregar la constante (intercepto) a las variables independientes
X1 = sm.add_constant(X1)

# Ajustar el modelo usando OLS
model1 = sm.OLS(y1, X1)
results1 = model1.fit()

# Mostrar el resumen del modelo
print(results1.summary())
```

```
                            OLS Regression Results
==============================================================================
==
Dep. Variable:     asistentes_totales   R-squared:                       0.4
47
Model:                            OLS   Adj. R-squared:                  0.4
40
Method:                 Least Squares   F-statistic:                     58.
28
Date:                Mon, 25 Nov 2024   Prob (F-statistic):           2.44e-
44
Time:                        11:14:46   Log-Likelihood:                -264
2.6
No. Observations:                 366   AIC:                             529
7.
Df Residuals:                     360   BIC:                             532
1.
Df Model:                           5
Covariance Type:            nonrobust
==============================================================================
============
                            coef    std err          t      P>|t|      [0.025
0.975]
------------------------------------------------------------------------------
------------
const                 -559.4356    116.855     -4.787      0.000    -789.241
-329.631
temperatura_promedio    32.0352      5.740      5.581      0.000      20.747
43.323
mes_marzo              681.2852     63.403     10.745      0.000     556.598
805.972
mes_abril              354.0969     67.275      5.263      0.000     221.795
486.398
mes_mayo               246.9681     74.120      3.332      0.001     101.207
392.730
día_Sunday             400.5772     49.948      8.020      0.000     302.350
498.805
==============================================================================
==
Omnibus:                      314.794   Durbin-Watson:                   0.9
04
Prob(Omnibus):                  0.000   Jarque-Bera (JB):             8737.3
55
Skew:                           3.454   Prob(JB):                         0.
00
Kurtosis:                      25.918   Cond. No.                         15
3.
==============================================================================
==

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is corre
ctly specified.
```

Hacemos una regresión lineal para predecir la cantidad de personas que asistirán al parque segun ciertas características y se oobtiene los siguiente:

- Temperatura promedio: Por cada unidad que se mueva la temperatura promedio del día afecta 32.0352 a la cantidad de personas.
- mes_marzo: Esto significa que si es marzo se esperan 681 personas.
- mes_abril: Esto significa que si es abril se esperan 354 personas.
- mes_mayo: Esto significa que si es mayo se esperan 246 personas.
- día_Sunday: Esto significa que si es domingo se esperan 400 personas.

El modelo tiene una R^2 de 0.447, por lo que explica casi la mitad de la variación de los datos, también tiene un F-estadístico muy bajo lo que significa que al menos una de las variables impacta significativamente a la cantidad de asistentes. Cabe resaltar que está segunda regresión nos da un mejor modelo.

In [49]:
```
new_day_data1 = {
    'const': [1],
    'temperatura_promedio': [27],
    'mes_marzo': [1],
    'mes_abril': [0],
    'mes_mayo' : [0],
    'día_Sunday' : [1]
}

new_day_data1 = pd.DataFrame(new_day_data1)

asistentes_predecidos1 = results1.predict(new_day_data1)

print(f"Asistentes predecidos del nuevo día: {asistentes_predecidos1[0]:,.2f
```

```
Asistentes predecidos del nuevo día: 1,387.38
```

Regresión semanal

In [50]:
```
df['semana'] = pd.Categorical(df['semana'], categories=[
    'semana 1', 'semana 2', 'semana 3', 'semana 4', 'semana 5', 'semana 6',
    'semana 11', 'semana 12', 'semana 13', 'semana 14', 'semana 15', 'semana
    'semana 21', 'semana 22', 'semana 23', 'semana 24', 'semana 25', 'semana
    'semana 31', 'semana 32', 'semana 33', 'semana 34', 'semana 35', 'semana
    'semana 41', 'semana 42', 'semana 43', 'semana 44', 'semana 45', 'semana
    'semana 51', 'semana 52', 'semana 53'
], ordered=True)
df_prom_suma = df.groupby('semana')['temperatura_promedio'].mean()
df_prom_suma.head()

df_suma = df.groupby('semana')['asistentes_totales','nomina'].sum()

df_semanal = pd.concat([df_prom_suma, df_suma], axis=1)
```

In [51]:
```
X_semanal = df_semanal[['temperatura_promedio','nomina']].reset_index(drop=T
y_semanal = df_semanal['asistentes_totales'].reset_index(drop=True)

# Agregar la constante (intercepto) a las variables independientes
X_semanal = sm.add_constant(X_semanal)
```

```
# Ajustar el modelo usando OLS
model_semanal= sm.OLS(y_semanal, X_semanal)
results_semanal = model_semanal.fit()

# Mostrar el resumen del modelo
print(results_semanal.summary())
```

```
                            OLS Regression Results
==============================================================================
==
Dep. Variable:     asistentes_totales   R-squared:                       0.3
48
Model:                            OLS   Adj. R-squared:                  0.3
22
Method:                 Least Squares   F-statistic:                     13.
36
Date:                Mon, 25 Nov 2024   Prob (F-statistic):           2.25e-
05
Time:                        11:14:46   Log-Likelihood:                -473.
18
No. Observations:                  53   AIC:                             95
2.4
Df Residuals:                      50   BIC:                             95
8.3
Df Model:                           2
Covariance Type:            nonrobust
==============================================================================
============
                            coef    std err          t      P>|t|      [0.025
0.975]
------------------------------------------------------------------------------
------------
const                -4889.0448   1603.071     -3.050      0.004   -8108.908
-1669.182
temperatura_promedio   252.5091     83.441      3.026      0.004      84.912
420.106
nomina                   0.0560      0.023      2.466      0.017       0.010
0.102
==============================================================================
==
Omnibus:                       59.148   Durbin-Watson:                   0.7
07
Prob(Omnibus):                  0.000   Jarque-Bera (JB):              370.8
61
Skew:                           2.993   Prob(JB):                     2.94e-
81
Kurtosis:                      14.493   Cond. No.                     1.85e+
05
==============================================================================
==

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is corre
ctly specified.
[2] The condition number is large, 1.85e+05. This might indicate that there
are
strong multicollinearity or other numerical problems.
```

Hacemos una regresión lineal para predecir la cantidad de personas que asistirán al parque segun ciertas la temperatura promedio semanal y la cantidad total pagada por semana y se obtiene los siguiente:

- Temperatura promedio: Por cada unidad que se mueva la temperatura promedio de la semana afecta en 252.5091 a la cantidad de asistentes en dicha semana.
- Cantidad total pagada en nómina por semana: Por cada unidad que se mueva la aantidad total pagada en nómina por semana afecta en 0.0560 a la cantidad de asistentes en dicha semana.

Estos coeficientes son de esta manera debido al rango de valores de cada una de las variables, en el caso de la temperatura promedio, esta se encuentra en promedio entre los 15 y los 27 grados Celsius, mientras que la cantidad pagada en nómina se encuentra entre los 15,000 y los 30,000 pesos, la mayoría de lo valores estando entre los 30,000 y los 40,000 pesos. Es por esta gran diferenica entre los valores de las variables que los coeficientes son tan diferentes.

El modelo tiene una R^2 de 0.348, por lo que explica muy poca variación de los datos pero también tiene un F-estadístico muy bajo lo que significa que al menos una de las variables impacta significativamente a la cantidad de asistentes.

In [52]:
```
new_day_data_semanal = {
    'const': [1],
    'temperatura_promedio': [25],
    'nomina': [15000]
}

new_day_data_semanal = pd.DataFrame(new_day_data_semanal)

asistentes_predecidos_semanal = results_semanal.predict(new_day_data_semanal

print(f"Asistentes predecidos del nuevo día: {asistentes_predecidos_semanal[
```

```
Asistentes predecidos del nuevo día: 2,263.39
```

Regresión semanal estandarizada

In [53]:
```
# Separar variables numéricas y categóricas
numerical_features = ['nomina','temperatura_promedio']
categorical_features = []

# Hacer las categóricas dummies
#encoded_features = pd.get_dummies(df[categorical_features],
               #columns=categorical_features,
               #drop_first=True)

# Estandarizar variables numéricas
data_to_model_standarized = StandardScaler().fit_transform(df_semanal[numeri

# Hacer dataframe variables numéricas
df_semanal_est = pd.DataFrame(data_to_model_standarized,
                              columns=numerical_features)

# Acomodar variables categóricas
#encoded_features_df = encoded_features.reset_index()
```

```
# Juntar ambas variables
#data_to_model = data_to_model_df.merge(encoded_features_df, on='index')
#data_to_model = data_to_model.drop('index', axis=1)
df_semanal_est.head()
```

Out[53]:

	nomina	temperatura_promedio
0	0.173028	0.366018
1	0.152742	0.349359
2	0.186271	0.432652
3	0.102242	0.182773
4	0.017847	0.141127

In [54]:

```
X_semanal_est = df_semanal_est[['temperatura_promedio','nomina']].reset_inde
y_semanal_est = df_semanal['asistentes_totales'].reset_index(drop=True)

# Agregar la constante (intercepto) a las variables independientes
X_semanal_est = sm.add_constant(X_semanal_est)

# Ajustar el modelo usando OLS
model_semanal_est= sm.OLS(y_semanal_est, X_semanal_est)
results_semanal_est = model_semanal_est.fit()

# Mostrar el resumen del modelo
print(results_semanal_est.summary())
```

```
                            OLS Regression Results
==============================================================================
==
Dep. Variable:     asistentes_totales   R-squared:                       0.3
48
Model:                            OLS   Adj. R-squared:                  0.3
22
Method:                 Least Squares   F-statistic:                     13.
36
Date:                Mon, 25 Nov 2024   Prob (F-statistic):           2.25e-
05
Time:                        11:14:46   Log-Likelihood:                -473.
18
No. Observations:                  53   AIC:                             95
2.4
Df Residuals:                      50   BIC:                             95
8.3
Df Model:                           2
Covariance Type:            nonrobust
==============================================================================
============
                            coef    std err          t      P>|t|      [0.025
0.975]
------------------------------------------------------------------------------
------------
const                  1903.1132    258.002      7.376      0.000    1384.901
2421.326
temperatura_promedio    866.1646    286.223      3.026      0.004     291.268
1441.061
nomina                  705.9046    286.223      2.466      0.017     131.008
1280.801
==============================================================================
==
Omnibus:                       59.148   Durbin-Watson:                   0.7
07
Prob(Omnibus):                  0.000   Jarque-Bera (JB):              370.8
61
Skew:                           2.993   Prob(JB):                     2.94e-
81
Kurtosis:                      14.493   Cond. No.                         1.
59
==============================================================================
==

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is corre
ctly specified.
```

Para esta regresión lineal se estandarizaron los datos de entrada al modelo, esto con el objetivo de hacer una comparación entre los coeficientes de temperatura y nómina, ya que su valor numérico es muy distinto lo cual complica la comparación de sus coeficientes. Los resultados del modelo muestran que la temperatura promedio es ligeramente más importante que el pago de nómina para calcular la cantidad de visitantes al parque.

In [55]:
```
new_day_data_semanal = {
    'const': [1],
    'temperatura_promedio': [0.366018],
    'nomina': [0.173028]
}

new_day_data_semanal = pd.DataFrame(new_day_data_semanal)

asistentes_predecidos_semanal = results_semanal_est.predict(new_day_data_sem

print(f"Asistentes predecidos del nuevo día: {asistentes_predecidos_semanal[
```

```
Asistentes predecidos del nuevo día: 2,342.29
```

Predicción con series de tiempo

Datos

In [56]:
```
df_ts = df[['fecha','asistentes_totales']]
df_ts.set_index('fecha', inplace=True)
df_ts.head()
```

Out[56]:

fecha	asistentes_totales
2023-08-01	189
2023-08-02	286
2023-08-03	172
2023-08-04	199
2023-08-05	255

Definición del Modelo

In [57]:
```
model_ts = auto_timeseries(
    score_type='rmse',       # Métrica de evaluación
    time_interval='D',       # Intervalo diario
    non_seasonal_pdq=None,   # Para modelos SARIMAX
    seasonality=False,       # Deshabilitar búsqueda de estacionalidad (se p
    model_type='best',       # Seleccionar el mejor modelo
    verbose=2                # Nivel de verbosidad
)
# ['best', 'prophet', 'stats', 'ml', 'arima', 'ARIMA', 'Prophet', 'SARIMAX',
```

In [58]:
```
train_size = int(0.75 * len(df_ts))
train_df = df_ts[:train_size]
test_df = df_ts[train_size:]

model_ts.fit(
```

```
    traindata=train_df,
    ts_column=train_df.index.name,
    target='asistentes_totales'
)
```

```
Start of Fit.....
    Target variable given as = asistentes_totales
Start of loading of data.....
    Inputs: ts_column = fecha, sep = ,, target = ['asistentes_totales']
    Using given input: pandas dataframe...
    train time series fecha column is the index on test data...
    train data shape = (274, 1)
Alert: Could not detect strf_time_format of fecha. Provide strf_time format
during "setup" for better results.

Running Augmented Dickey-Fuller test with paramters:
    maxlag: 31 regression: c autolag: BIC
Data is stationary after one differencing
There is 1 differencing needed in this datasets for VAR model
```

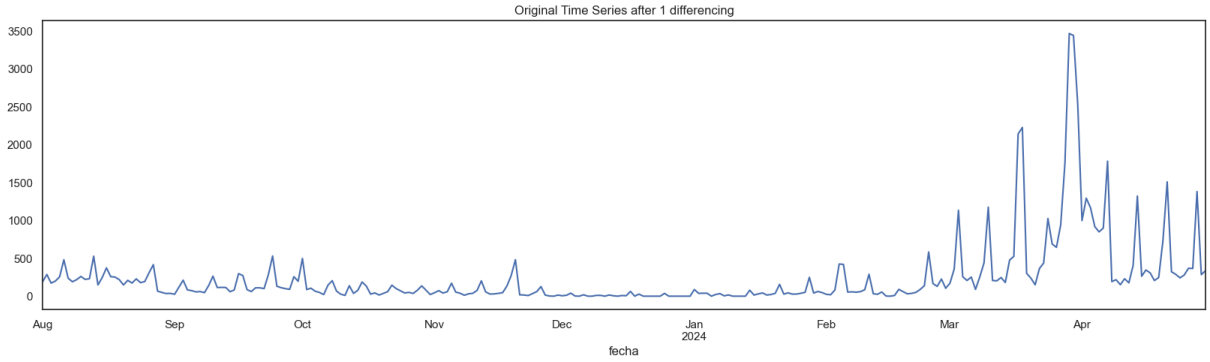

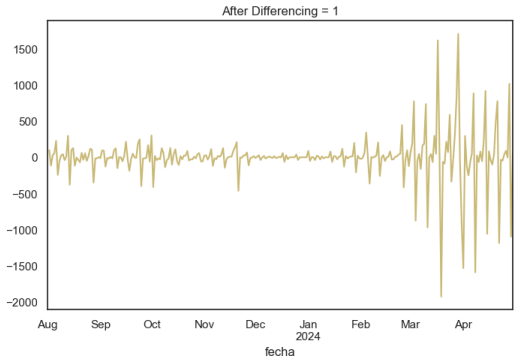

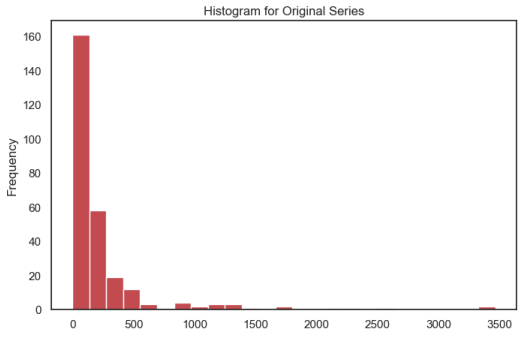

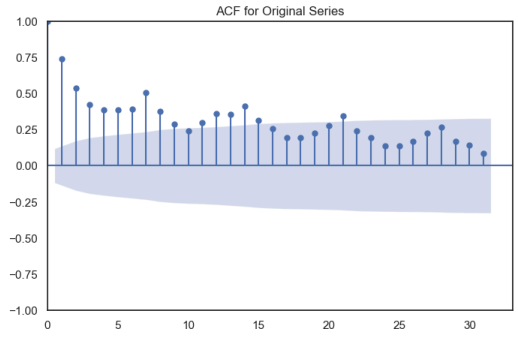

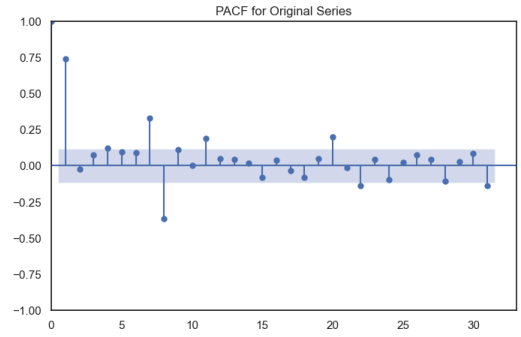

```
11:14:46 - cmdstanpy - INFO - Chain [1] start processing
11:14:47 - cmdstanpy - INFO - Chain [1] done processing
Time Interval is given as D
    Correct Time interval given as a valid Pandas date-range frequency...
WARNING: Running best models will take time... Be Patient...


================================================
Building Prophet Model
================================================



Running Facebook Prophet Model...
kwargs for Prophet model: {'iter': 100}
    Fit-Predict data (shape=(274, 2)) with Confidence Interval = 0.95...
  Starting Prophet Fit
      No seasonality assumed since seasonality flag is set to False
  Starting Prophet Cross Validation
Max. iterations using expanding window cross validation = 5

Fold Number: 1 --> Train Shape: 249 Test Shape: 5
11:14:47 - cmdstanpy - INFO - Chain [1] start processing
11:14:47 - cmdstanpy - INFO - Chain [1] done processing
11:14:47 - cmdstanpy - INFO - Chain [1] start processing
11:14:47 - cmdstanpy - INFO - Chain [1] done processing
11:14:47 - cmdstanpy - INFO - Chain [1] start processing
11:14:47 - cmdstanpy - INFO - Chain [1] done processing
11:14:47 - cmdstanpy - INFO - Chain [1] start processing
    RMSE = 740.77
    Std Deviation of actuals = 630.02
    Normalized RMSE (as pct of std dev) = 118%
Cross Validation window: 1 completed

Fold Number: 2 --> Train Shape: 254 Test Shape: 5
    RMSE = 708.64
    Std Deviation of actuals = 427.37
    Normalized RMSE (as pct of std dev) = 166%
Cross Validation window: 2 completed

Fold Number: 3 --> Train Shape: 259 Test Shape: 5
    RMSE = 578.77
    Std Deviation of actuals = 189.00
    Normalized RMSE (as pct of std dev) = 306%
Cross Validation window: 3 completed

Fold Number: 4 --> Train Shape: 264 Test Shape: 5
    RMSE = 525.90
    Std Deviation of actuals = 490.48
    Normalized RMSE (as pct of std dev) = 107%
Cross Validation window: 4 completed

Fold Number: 5 --> Train Shape: 269 Test Shape: 5
```

```
11:14:47 - cmdstanpy - INFO - Chain [1] done processing
11:14:47 - cmdstanpy - INFO - Chain [1] start processing
11:14:47 - cmdstanpy - INFO - Chain [1] done processing
```

```
    RMSE = 463.17
    Std Deviation of actuals = 417.79
    Normalized RMSE (as pct of std dev) = 111%
Cross Validation window: 5 completed

----------------------------------------
Model Cross Validation Results:
----------------------------------------
    MAE (Mean Absolute Error = 568.64
    MSE (Mean Squared Error = 375395.31
    MAPE (Mean Absolute Percent Error) = 213%
    RMSE (Root Mean Squared Error) = 612.6951
    Normalized RMSE (MinMax) = 38%
    Normalized RMSE (as Std Dev of Actuals)= 130%
Time Taken = 1 seconds
  End of Prophet Fit


================================================
Building Auto SARIMAX Model
================================================
```

Running Auto SARIMAX Model...

```
Best Parameters:
p: None, d: None, q: None
P: None, D: None, Q: None
Seasonality: False
Seasonal Period: 12

Fold Number: 1 --> Train Shape: 249 Test Shape: 5

    Finding the best parameters using AutoArima:
Performing stepwise search to minimize aic
 ARIMA(0,1,0)(0,0,0)[0] intercept   : AIC=3505.036, Time=0.02 sec
 ARIMA(1,1,0)(0,0,0)[0] intercept   : AIC=3506.696, Time=0.01 sec
 ARIMA(0,1,1)(0,0,0)[0] intercept   : AIC=3506.432, Time=0.02 sec
 ARIMA(0,1,0)(0,0,0)[0]             : AIC=3503.058, Time=0.00 sec
 ARIMA(1,1,1)(0,0,0)[0] intercept   : AIC=3477.543, Time=0.04 sec
 ARIMA(2,1,1)(0,0,0)[0] intercept   : AIC=3460.511, Time=0.06 sec
 ARIMA(2,1,0)(0,0,0)[0] intercept   : AIC=3495.165, Time=0.01 sec
 ARIMA(3,1,1)(0,0,0)[0] intercept   : AIC=3461.992, Time=0.08 sec
 ARIMA(2,1,2)(0,0,0)[0] intercept   : AIC=inf, Time=0.11 sec
 ARIMA(1,1,2)(0,0,0)[0] intercept   : AIC=3464.354, Time=0.05 sec
 ARIMA(3,1,0)(0,0,0)[0] intercept   : AIC=3487.182, Time=0.02 sec
 ARIMA(3,1,2)(0,0,0)[0] intercept   : AIC=inf, Time=0.13 sec
 ARIMA(2,1,1)(0,0,0)[0]             : AIC=3459.860, Time=0.03 sec
 ARIMA(1,1,1)(0,0,0)[0]             : AIC=3476.670, Time=0.02 sec
 ARIMA(2,1,0)(0,0,0)[0]             : AIC=3493.204, Time=0.01 sec
 ARIMA(3,1,1)(0,0,0)[0]             : AIC=3461.366, Time=0.05 sec
 ARIMA(2,1,2)(0,0,0)[0]             : AIC=3461.123, Time=0.07 sec
 ARIMA(1,1,0)(0,0,0)[0]             : AIC=3504.716, Time=0.01 sec
 ARIMA(1,1,2)(0,0,0)[0]             : AIC=3463.611, Time=0.03 sec
```

```
 ARIMA(3,1,0)(0,0,0)[0]             : AIC=3485.250, Time=0.01 sec
 ARIMA(3,1,2)(0,0,0)[0]             : AIC=inf, Time=0.08 sec

Best model:  ARIMA(2,1,1)(0,0,0)[0]
Total fit time: 0.871 seconds

Best model is a Seasonal SARIMAX(2,1,1)*(0,0,0,12), aic = 3459.860
Static Forecasts:
    RMSE = 900.42
    Std Deviation of Actuals = 630.02
    Normalized RMSE (as pct of std dev) = 142.9%

Fold Number: 2 --> Train Shape: 254 Test Shape: 5

    Finding the best parameters using AutoArima:
Performing stepwise search to minimize aic
 ARIMA(0,1,0)(0,0,0)[0] intercept   : AIC=3609.980, Time=0.00 sec
 ARIMA(1,1,0)(0,0,0)[0] intercept   : AIC=3611.767, Time=0.01 sec
 ARIMA(0,1,1)(0,0,0)[0] intercept   : AIC=3611.613, Time=0.02 sec
 ARIMA(0,1,0)(0,0,0)[0]             : AIC=3607.981, Time=0.00 sec
 ARIMA(1,1,1)(0,0,0)[0] intercept   : AIC=3580.161, Time=0.04 sec
 ARIMA(2,1,1)(0,0,0)[0] intercept   : AIC=3572.914, Time=0.07 sec
 ARIMA(2,1,0)(0,0,0)[0] intercept   : AIC=3603.706, Time=0.01 sec
 ARIMA(3,1,1)(0,0,0)[0] intercept   : AIC=3574.407, Time=0.08 sec
 ARIMA(2,1,2)(0,0,0)[0] intercept   : AIC=3570.447, Time=0.06 sec
 ARIMA(1,1,2)(0,0,0)[0] intercept   : AIC=3574.640, Time=0.05 sec
 ARIMA(3,1,2)(0,0,0)[0] intercept   : AIC=3576.257, Time=0.08 sec
 ARIMA(2,1,3)(0,0,0)[0] intercept   : AIC=3571.330, Time=0.12 sec
 ARIMA(1,1,3)(0,0,0)[0] intercept   : AIC=3571.839, Time=0.09 sec
 ARIMA(3,1,3)(0,0,0)[0] intercept   : AIC=inf, Time=0.15 sec
 ARIMA(2,1,2)(0,0,0)[0]             : AIC=3569.203, Time=0.05 sec
 ARIMA(1,1,2)(0,0,0)[0]             : AIC=3573.421, Time=0.04 sec
 ARIMA(2,1,1)(0,0,0)[0]             : AIC=3571.664, Time=0.05 sec
 ARIMA(3,1,2)(0,0,0)[0]             : AIC=3574.977, Time=0.05 sec
 ARIMA(2,1,3)(0,0,0)[0]             : AIC=3570.073, Time=0.09 sec
 ARIMA(1,1,1)(0,0,0)[0]             : AIC=3578.951, Time=0.03 sec
 ARIMA(1,1,3)(0,0,0)[0]             : AIC=3570.630, Time=0.05 sec
 ARIMA(3,1,1)(0,0,0)[0]             : AIC=3573.125, Time=0.14 sec
 ARIMA(3,1,3)(0,0,0)[0]             : AIC=inf, Time=0.14 sec

Best model:  ARIMA(2,1,2)(0,0,0)[0]
Total fit time: 1.444 seconds

Best model is a Seasonal SARIMAX(2,1,2)*(0,0,0,12), aic = 3569.203
Static Forecasts:
    RMSE = 384.77
    Std Deviation of Actuals = 427.37
    Normalized RMSE (as pct of std dev) = 90.0%

Fold Number: 3 --> Train Shape: 259 Test Shape: 5

    Finding the best parameters using AutoArima:
Performing stepwise search to minimize aic
 ARIMA(0,1,0)(0,0,0)[0] intercept   : AIC=3697.928, Time=0.00 sec
 ARIMA(1,1,0)(0,0,0)[0] intercept   : AIC=3699.020, Time=0.01 sec
 ARIMA(0,1,1)(0,0,0)[0] intercept   : AIC=3698.303, Time=0.02 sec
```

```
 ARIMA(0,1,0)(0,0,0)[0]             : AIC=3695.929, Time=0.00 sec
 ARIMA(1,1,1)(0,0,0)[0] intercept   : AIC=3664.843, Time=0.04 sec
 ARIMA(2,1,1)(0,0,0)[0] intercept   : AIC=3661.168, Time=0.06 sec
 ARIMA(2,1,0)(0,0,0)[0] intercept   : AIC=3690.404, Time=0.01 sec
 ARIMA(3,1,1)(0,0,0)[0] intercept   : AIC=3663.144, Time=0.08 sec
 ARIMA(2,1,2)(0,0,0)[0] intercept   : AIC=3652.388, Time=0.07 sec
 ARIMA(1,1,2)(0,0,0)[0] intercept   : AIC=3661.707, Time=0.05 sec
 ARIMA(3,1,2)(0,0,0)[0] intercept   : AIC=3653.783, Time=0.11 sec
 ARIMA(2,1,3)(0,0,0)[0] intercept   : AIC=3662.861, Time=0.11 sec
 ARIMA(1,1,3)(0,0,0)[0] intercept   : AIC=3666.814, Time=0.07 sec
 ARIMA(3,1,3)(0,0,0)[0] intercept   : AIC=inf, Time=0.16 sec
 ARIMA(2,1,2)(0,0,0)[0]             : AIC=3650.971, Time=0.05 sec
 ARIMA(1,1,2)(0,0,0)[0]             : AIC=3660.197, Time=0.04 sec
 ARIMA(2,1,1)(0,0,0)[0]             : AIC=3659.562, Time=0.03 sec
 ARIMA(3,1,2)(0,0,0)[0]             : AIC=3652.305, Time=0.04 sec
 ARIMA(2,1,3)(0,0,0)[0]             : AIC=3661.031, Time=0.06 sec
 ARIMA(1,1,1)(0,0,0)[0]             : AIC=3663.484, Time=0.03 sec
 ARIMA(1,1,3)(0,0,0)[0]             : AIC=3664.849, Time=0.05 sec
 ARIMA(3,1,1)(0,0,0)[0]             : AIC=3661.508, Time=0.05 sec
 ARIMA(3,1,3)(0,0,0)[0]             : AIC=inf, Time=0.13 sec

Best model:  ARIMA(2,1,2)(0,0,0)[0]
Total fit time: 1.287 seconds

Best model is a Seasonal SARIMAX(2,1,2)*(0,0,0,12), aic = 3650.971
Static Forecasts:
    RMSE = 307.90
    Std Deviation of Actuals = 189.00
    Normalized RMSE (as pct of std dev) = 162.9%

Fold Number: 4 --> Train Shape: 264 Test Shape: 5

    Finding the best parameters using AutoArima:
Performing stepwise search to minimize aic
 ARIMA(0,1,0)(0,0,0)[0] intercept   : AIC=3767.152, Time=0.00 sec
 ARIMA(1,1,0)(0,0,0)[0] intercept   : AIC=3768.190, Time=0.01 sec
 ARIMA(0,1,1)(0,0,0)[0] intercept   : AIC=3767.485, Time=0.02 sec
 ARIMA(0,1,0)(0,0,0)[0]             : AIC=3765.164, Time=0.00 sec
 ARIMA(1,1,1)(0,0,0)[0] intercept   : AIC=3733.533, Time=0.05 sec
 ARIMA(2,1,1)(0,0,0)[0] intercept   : AIC=3729.997, Time=0.06 sec
 ARIMA(2,1,0)(0,0,0)[0] intercept   : AIC=3760.269, Time=0.01 sec
 ARIMA(3,1,1)(0,0,0)[0] intercept   : AIC=3731.917, Time=0.09 sec
 ARIMA(2,1,2)(0,0,0)[0] intercept   : AIC=3721.438, Time=0.07 sec
 ARIMA(1,1,2)(0,0,0)[0] intercept   : AIC=3730.574, Time=0.04 sec
 ARIMA(3,1,2)(0,0,0)[0] intercept   : AIC=3722.724, Time=0.11 sec
 ARIMA(2,1,3)(0,0,0)[0] intercept   : AIC=3733.006, Time=0.12 sec
 ARIMA(1,1,3)(0,0,0)[0] intercept   : AIC=3731.008, Time=0.10 sec
 ARIMA(3,1,3)(0,0,0)[0] intercept   : AIC=inf, Time=0.15 sec
 ARIMA(2,1,2)(0,0,0)[0]             : AIC=3719.943, Time=0.04 sec
 ARIMA(1,1,2)(0,0,0)[0]             : AIC=3728.981, Time=0.04 sec
 ARIMA(2,1,1)(0,0,0)[0]             : AIC=3728.299, Time=0.04 sec
 ARIMA(3,1,2)(0,0,0)[0]             : AIC=3721.126, Time=0.08 sec
 ARIMA(2,1,3)(0,0,0)[0]             : AIC=3731.178, Time=0.07 sec
 ARIMA(1,1,1)(0,0,0)[0]             : AIC=3732.105, Time=0.03 sec
 ARIMA(1,1,3)(0,0,0)[0]             : AIC=3729.198, Time=0.05 sec
 ARIMA(3,1,1)(0,0,0)[0]             : AIC=3730.163, Time=0.05 sec
```

```
 ARIMA(3,1,3)(0,0,0)[0]             : AIC=inf, Time=0.15 sec

Best model:  ARIMA(2,1,2)(0,0,0)[0]
Total fit time: 1.369 seconds

Best model is a Seasonal SARIMAX(2,1,2)*(0,0,0,12), aic = 3719.943
Static Forecasts:
    RMSE = 498.63
    Std Deviation of Actuals = 490.48
    Normalized RMSE (as pct of std dev) = 101.7%

Fold Number: 5 --> Train Shape: 269 Test Shape: 5

    Finding the best parameters using AutoArima:
Performing stepwise search to minimize aic
 ARIMA(0,1,0)(0,0,0)[0] intercept   : AIC=3854.196, Time=0.00 sec
 ARIMA(1,1,0)(0,0,0)[0] intercept   : AIC=3854.723, Time=0.01 sec
 ARIMA(0,1,1)(0,0,0)[0] intercept   : AIC=3853.564, Time=0.01 sec
 ARIMA(0,1,0)(0,0,0)[0]             : AIC=3852.197, Time=0.00 sec
 ARIMA(1,1,1)(0,0,0)[0] intercept   : AIC=3818.056, Time=0.04 sec
 ARIMA(2,1,1)(0,0,0)[0] intercept   : AIC=3814.489, Time=0.06 sec
 ARIMA(2,1,0)(0,0,0)[0] intercept   : AIC=3845.912, Time=0.01 sec
 ARIMA(3,1,1)(0,0,0)[0] intercept   : AIC=3816.258, Time=0.08 sec
 ARIMA(2,1,2)(0,0,0)[0] intercept   : AIC=3805.459, Time=0.13 sec
 ARIMA(1,1,2)(0,0,0)[0] intercept   : AIC=3815.209, Time=0.06 sec
 ARIMA(3,1,2)(0,0,0)[0] intercept   : AIC=3807.081, Time=0.07 sec
 ARIMA(2,1,3)(0,0,0)[0] intercept   : AIC=3815.387, Time=0.05 sec
 ARIMA(1,1,3)(0,0,0)[0] intercept   : AIC=3818.595, Time=0.07 sec
 ARIMA(3,1,3)(0,0,0)[0] intercept   : AIC=inf, Time=0.16 sec
 ARIMA(2,1,2)(0,0,0)[0]             : AIC=3803.741, Time=0.06 sec
 ARIMA(1,1,2)(0,0,0)[0]             : AIC=3813.401, Time=0.03 sec
 ARIMA(2,1,1)(0,0,0)[0]             : AIC=3812.608, Time=0.03 sec
 ARIMA(3,1,2)(0,0,0)[0]             : AIC=3805.290, Time=0.05 sec
 ARIMA(2,1,3)(0,0,0)[0]             : AIC=3813.417, Time=0.03 sec
 ARIMA(1,1,1)(0,0,0)[0]             : AIC=3816.417, Time=0.03 sec
 ARIMA(1,1,3)(0,0,0)[0]             : AIC=3816.616, Time=0.05 sec
 ARIMA(3,1,1)(0,0,0)[0]             : AIC=3814.341, Time=0.05 sec
 ARIMA(3,1,3)(0,0,0)[0]             : AIC=inf, Time=0.13 sec

Best model:  ARIMA(2,1,2)(0,0,0)[0]
Total fit time: 1.226 seconds

Best model is a Seasonal SARIMAX(2,1,2)*(0,0,0,12), aic = 3803.741
Static Forecasts:
    RMSE = 398.72
    Std Deviation of Actuals = 417.79
    Normalized RMSE (as pct of std dev) = 95.4%

SARIMAX RMSE (all folds): 498.0898
SARIMAX Norm RMSE (all folds): 109%


-----------------------------------------
Model Cross Validation Results:
-----------------------------------------
    MAE (Mean Absolute Error = 440.72
```

```
    MSE (Mean Squared Error = 292245.27
    MAPE (Mean Absolute Percent Error) = 156%
    RMSE (Root Mean Squared Error) = 540.5971
    Normalized RMSE (MinMax) = 33%
    Normalized RMSE (as Std Dev of Actuals)= 114%
```

Finding the best parameters using AutoArima:

```
Performing stepwise search to minimize aic
 ARIMA(0,1,0)(0,0,0)[0] intercept   : AIC=3942.589, Time=0.01 sec
 ARIMA(1,1,0)(0,0,0)[0] intercept   : AIC=3941.383, Time=0.01 sec
 ARIMA(0,1,1)(0,0,0)[0] intercept   : AIC=3938.930, Time=0.01 sec
 ARIMA(0,1,0)(0,0,0)[0]             : AIC=3940.590, Time=0.00 sec
 ARIMA(1,1,1)(0,0,0)[0] intercept   : AIC=3902.167, Time=0.05 sec
 ARIMA(2,1,1)(0,0,0)[0] intercept   : AIC=3900.330, Time=0.07 sec
 ARIMA(2,1,0)(0,0,0)[0] intercept   : AIC=3933.300, Time=0.01 sec
 ARIMA(3,1,1)(0,0,0)[0] intercept   : AIC=3901.899, Time=0.09 sec
 ARIMA(2,1,2)(0,0,0)[0] intercept   : AIC=3888.545, Time=0.09 sec
 ARIMA(1,1,2)(0,0,0)[0] intercept   : AIC=3900.885, Time=0.05 sec
 ARIMA(3,1,2)(0,0,0)[0] intercept   : AIC=3890.528, Time=0.09 sec
 ARIMA(2,1,3)(0,0,0)[0] intercept   : AIC=3897.459, Time=0.07 sec
 ARIMA(1,1,3)(0,0,0)[0] intercept   : AIC=3900.519, Time=0.06 sec
 ARIMA(3,1,3)(0,0,0)[0] intercept   : AIC=inf, Time=0.15 sec
 ARIMA(2,1,2)(0,0,0)[0]             : AIC=3886.765, Time=0.06 sec
 ARIMA(1,1,2)(0,0,0)[0]             : AIC=3899.054, Time=0.03 sec
 ARIMA(2,1,1)(0,0,0)[0]             : AIC=3898.451, Time=0.04 sec
 ARIMA(3,1,2)(0,0,0)[0]             : AIC=3888.731, Time=0.05 sec
 ARIMA(2,1,3)(0,0,0)[0]             : AIC=3895.545, Time=0.03 sec
 ARIMA(1,1,1)(0,0,0)[0]             : AIC=3900.452, Time=0.03 sec
 ARIMA(1,1,3)(0,0,0)[0]             : AIC=3898.562, Time=0.05 sec
 ARIMA(3,1,1)(0,0,0)[0]             : AIC=3899.976, Time=0.05 sec
 ARIMA(3,1,3)(0,0,0)[0]             : AIC=inf, Time=0.14 sec

Best model:  ARIMA(2,1,2)(0,0,0)[0]
Total fit time: 1.270 seconds

Best model is a Seasonal SARIMAX(2,1,2)*(0,0,0,12), aic = 3886.765
```

Refitting data with previously found best parameters

```
    Best aic metric = 3848.1
                               SARIMAX Results
==============================================================================
==
Dep. Variable:     asistentes_totales   No. Observations:                 2
74
Model:               SARIMAX(2, 1, 2)   Log Likelihood               -1917.0
73
Date:                Mon, 25 Nov 2024   AIC                            3848.1
47
Time:                        11:14:55   BIC                            3873.3
35
Sample:                    08-01-2023   HQIC                           3858.2
61
                         - 04-30-2024
Covariance Type:                 opg
==============================================================================
==
                 coef    std err          z      P>|z|      [0.025      0.97
```

```
5]
------------------------------------------------------------------------------
--
intercept     -4.5990      4.430     -1.038      0.299     -13.281       4.0
83
drift          0.0442      0.027      1.635      0.102      -0.009       0.0
97
ar.L1         -0.1695      0.059     -2.886      0.004      -0.285      -0.0
54
ar.L2          0.4547      0.050      9.042      0.000       0.356       0.5
53
ma.L1         -0.0609      0.129     -0.470      0.638      -0.315       0.1
93
ma.L2         -0.9377      0.117     -8.049      0.000      -1.166      -0.7
09
sigma2      8.805e+04   1.22e+04      7.208      0.000    6.41e+04    1.12e+
05
==============================================================================
=======
Ljung-Box (L1) (Q):                   0.03   Jarque-Bera (JB):
1796.50
Prob(Q):                              0.87   Prob(JB):
0.00
Heteroskedasticity (H):              19.06   Skew:
1.25
Prob(H) (two-sided):                  0.00   Kurtosis:
15.39
==============================================================================
=======

Warnings:
[1] Covariance matrix calculated using the outer product of gradients (compl
ex-step).


================================================
Building VAR Model - best suited for small datasets < 1000 rows and < 10 col
umns
================================================
```

No VAR model created since no explanatory variables given in data set

```
================================================
Building ML Model
================================================
```

Creating 2 lagged variables for Machine Learning model...

```
    You have set lag = 3 in auto_timeseries setup to feed prior targets. You
cannot set lags > 10 ...
### Be careful setting dask_xgboost_flag to True since dask is unstable and
doesn't work sometime's ###
```

```
########### Single-Label Regression Model Tuning and Training Started ####

Fitting ML model
    11 variables used in training ML model = ['asistentes_totales(t-1)', 'fe
cha_hour', 'fecha_minute', 'fecha_dayofweek', 'fecha_quarter', 'fecha_mont
h', 'fecha_year', 'fecha_dayofyear', 'fecha_dayofmonth', 'fecha_weekofyear',
'fecha_weekend']

Running Cross Validation using XGBoost model..
    Max. iterations using expanding window cross validation = 2
train fold shape (245, 11), test fold shape = (28, 11)
### Number of booster rounds = 250 for XGBoost which can be set during setup
####
    Hyper Param Tuning XGBoost with CPU parameters. This will take time. Ple
ase be patient...
Cross-validated Score = 238.844 in num rounds = 249
Time taken for Hyper Param tuning of XGBoost (in minutes) = 0.0
Top 10 features:
['fecha_year', 'asistentes_totales(t-1)', 'fecha_quarter', 'fecha_month', 'f
echa_dayofyear', 'fecha_dayofweek', 'fecha_dayofmonth', 'fecha_weekofyear',
'fecha_weekend']
    Time taken for training XGBoost on entire train data (in minutes) = 0.0
Returning the following:
    Model = <xgboost.core.Booster object at 0x16b435070>
    Scaler = Pipeline(steps=[('columntransformer',
                 ColumnTransformer(transformers=[('simpleimputer',
                                                  SimpleImputer(),
                                                  ['asistentes_totales(t-
1)',
                                                   'fecha_hour', 'fecha_minu
te',
                                                   'fecha_dayofweek',
                                                   'fecha_quarter',
                                                   'fecha_month', 'fecha_yea
r',
                                                   'fecha_dayofyear',
                                                   'fecha_dayofmonth',
                                                   'fecha_weekofyear',
                                                   'fecha_weekend'])])),
                ('maxabsscaler', MaxAbsScaler())])
    (3) sample predictions:[710.3362  747.2335  985.16724]
XGBoost model tuning completed
Target = asistentes_totales...CV results:
    RMSE = 434.64
    Std Deviation of actuals = 462.62
    Normalized RMSE (as pct of std dev) = 94%

Fitting model on entire train set. Please be patient...
    Time taken to train model (in seconds) = 0

Best Model is: ML
    Best Model (Mean CV) Score: 434.64


--------------------------------------------------
```

```
Total time taken: 10 seconds.
-------------------------------------------------


Leaderboard with best model on top of list:
           name        rmse
3            ML  434.636833
1  auto_SARIMAX  498.089770
0       Prophet  603.449065
2           VAR         inf
```

Out[58]: <auto_ts.auto_timeseries at 0x1671c77a0>

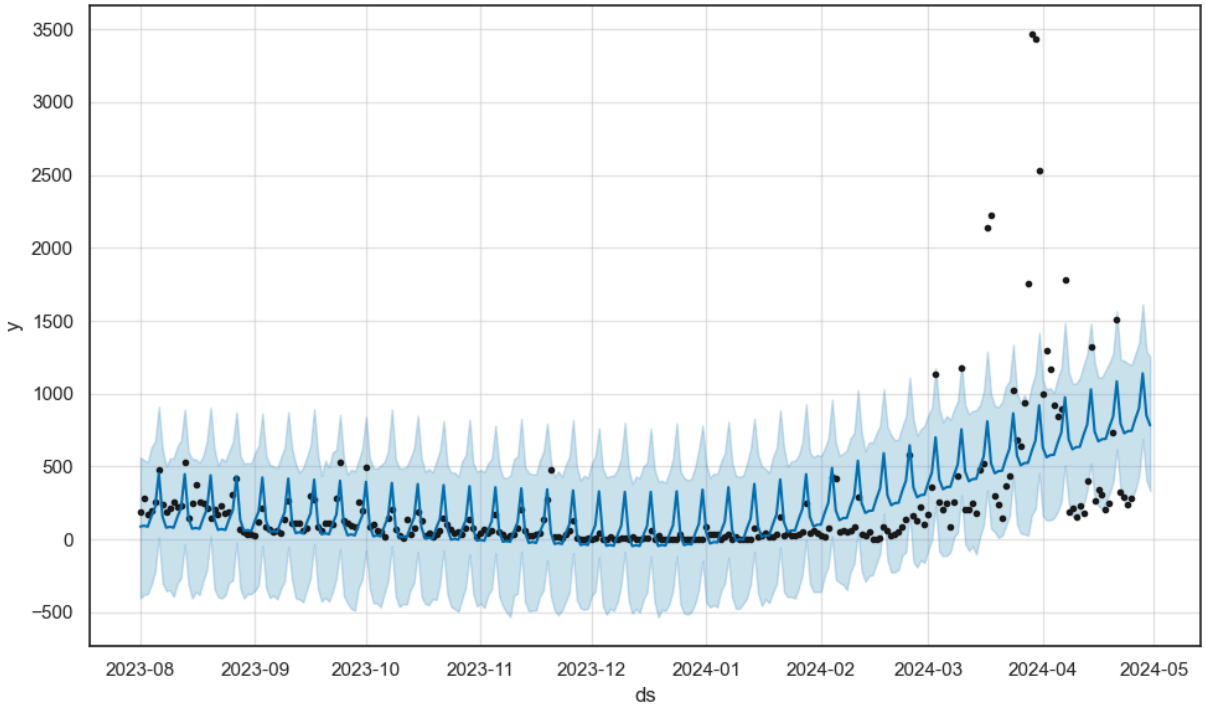

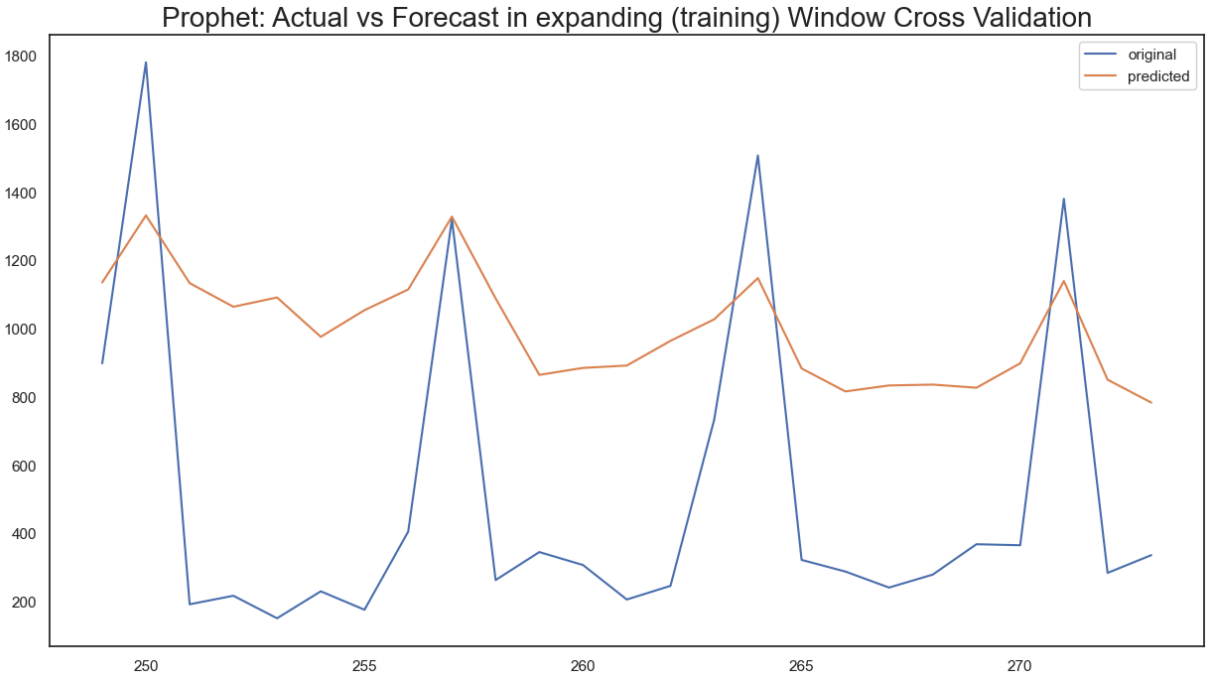

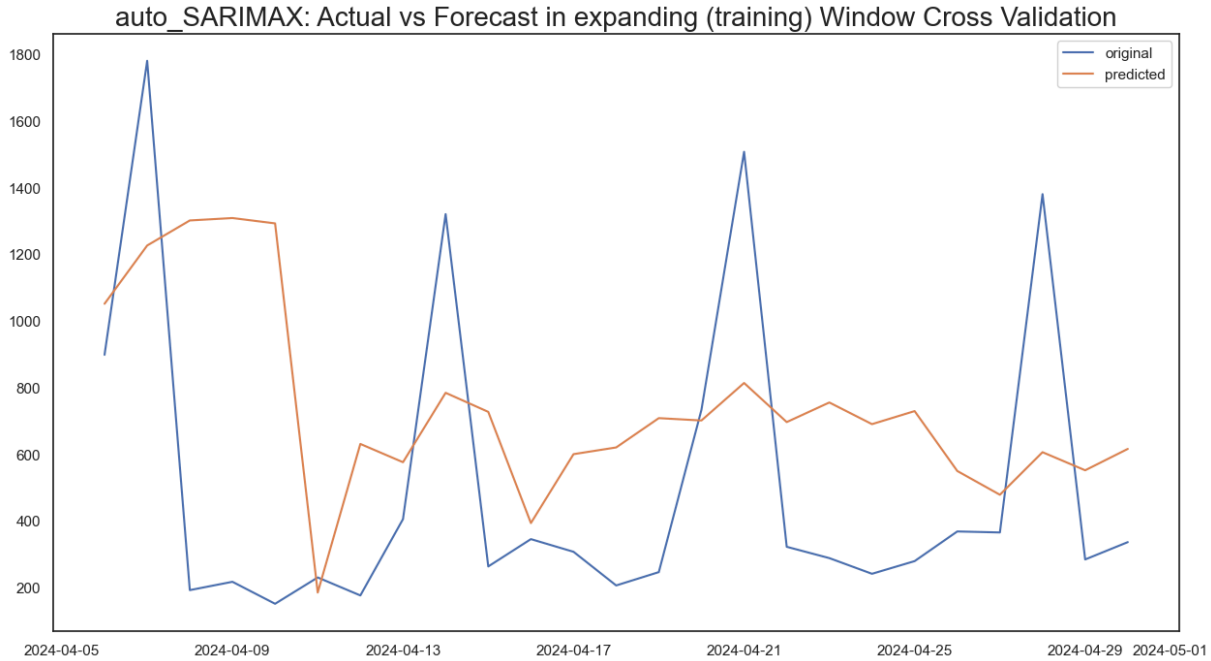
auto_SARIMAX: Actual vs Forecast in expanding (training) Window Cross Validation
original
predicted
1800
1600
1400
1200
1000
800
600
400
200
2024-04-05
2024-04-09
2024-04-13
2024-04-17
2024-04-21
2024-04-25
2024-04-29
2024-05-01

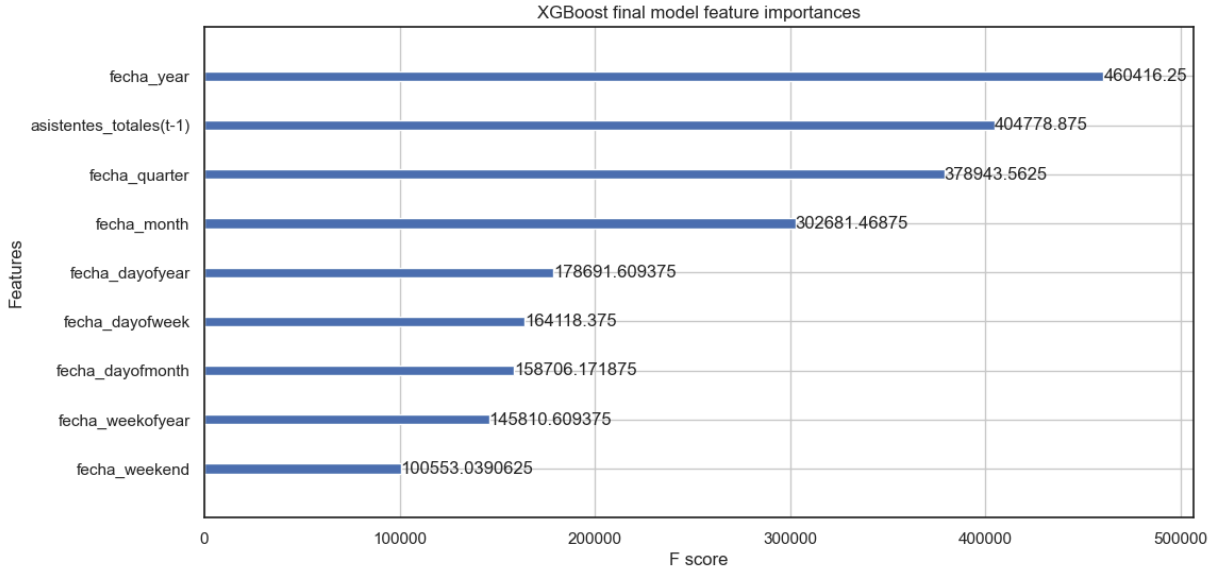
XGBoost final model feature importances
fecha_year
asistentes_totales(t-1)
fecha_quarter
fecha_month
fecha_dayofyear
fecha_dayofweek
fecha_dayofmonth
fecha_weekofyear
fecha_weekend
460416.25
404778.875
378943.5625
302681.46875
178691.609375
164118.375
158706.171875
145810.609375
100553.0390625
Features
0
100000
200000
300000
400000
500000
F score

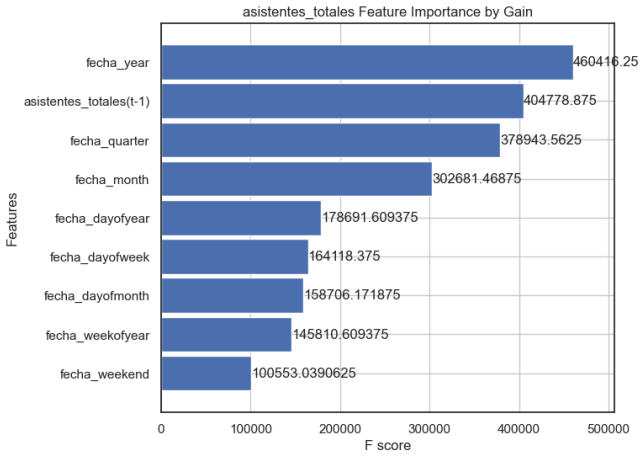
asistentes_totales Feature Importance by Gain
fecha_year
asistentes_totales(t-1)
fecha_quarter
fecha_month
fecha_dayofyear
fecha_dayofweek
fecha_dayofmonth
fecha_weekofyear
fecha_weekend
460416.25
404778.875
378943.5625
302681.46875
178691.609375
164118.375
158706.171875
145810.609375
100553.0390625
Features
0
100000
200000
300000
400000
500000
F score


asistentes_totales expanding window preds vs. actuals
actual
predicted
1750
1500
1250
1000
750
500
250
03
Apr
2024
04 05 06 07 08 09 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30
fecha

Test

In [59]:
```
forecast = model_ts.predict(testdata=test_df)
forecast
```

```
Predicting using test dataframe shape = (92, 1) for ML model
For large datasets: ML predictions will take time since it has to predict ea
ch row and use that for future predictions...
    Using given input: pandas dataframe...
    Alert: No strf_time_format given for fecha. Provide strf_time format dur
ing "setup" for better results.
ML predictions completed
```

Out[59]:

fecha	yhat	mean_se	mean_ci_lower	mean_ci_upper
2024-05-01	675.981689	NaN	NaN	NaN
2024-05-02	1215.401978	NaN	NaN	NaN
2024-05-03	716.235901	NaN	NaN	NaN
2024-05-04	738.473511	NaN	NaN	NaN
2024-05-05	1187.199951	NaN	NaN	NaN
...	...	...	...	...
2024-07-27	552.684204	NaN	NaN	NaN
2024-07-28	826.076599	NaN	NaN	NaN
2024-07-29	568.383362	NaN	NaN	NaN
2024-07-30	621.908508	NaN	NaN	NaN
2024-07-31	626.753418	NaN	NaN	NaN

92 rows × 4 columns

In [60]:
```
plt.figure(figsize=(12,6))
plt.plot(train_df.index, train_df['asistentes_totales'], label='Entrenamient
plt.plot(test_df.index, test_df['asistentes_totales'], label='Datos Reales',
plt.plot(test_df.index, forecast['yhat'], label='Predicción', linestyle='--'
plt.title('Predicción de Asistentes Totales Diarios')
plt.xlabel('Fecha')
plt.ylabel('Asistentes')
plt.legend()
plt.grid(True)
plt.show()

rmse = mean_squared_error(test_df['asistentes_totales'], forecast['yhat'], s
print(f'RMSE en el conjunto de prueba: {rmse:.2f}')
```

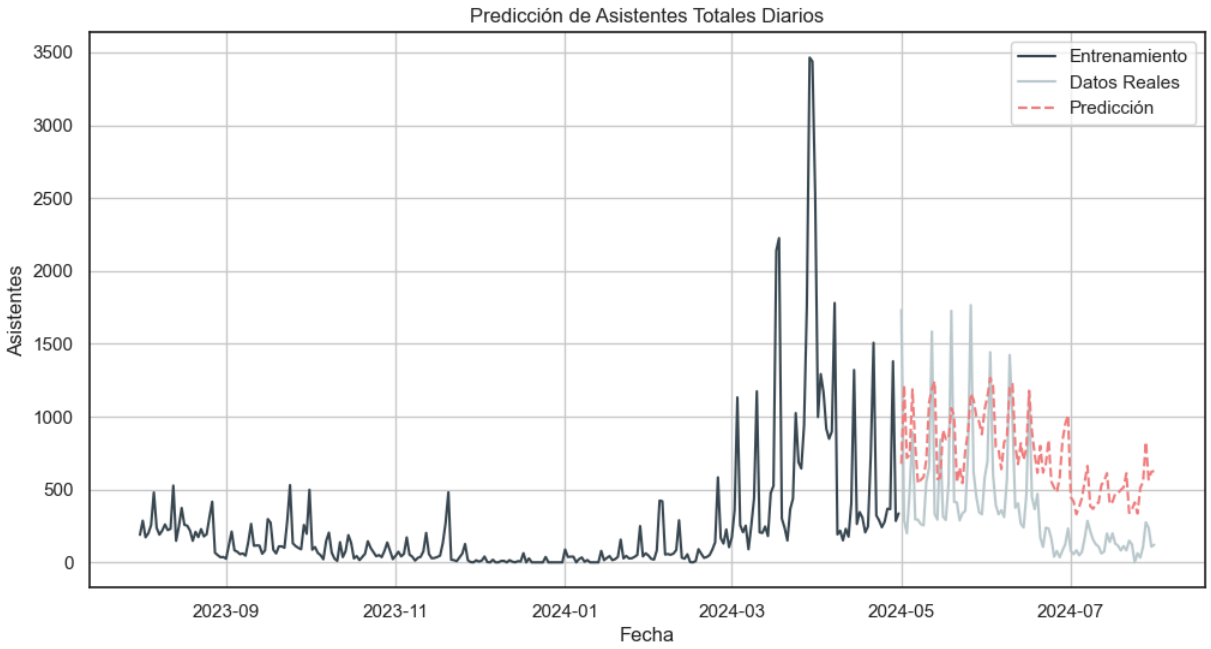


```
RMSE en el conjunto de prueba: 455.28
```

Predicciones Futuras

In [61]:
```
future_periods = 60
last_date = df_ts.index[-1]
future_dates = pd.date_range(start=last_date + pd.DateOffset(days=1), perioc

future_df = pd.DataFrame(index=future_dates)
future_forecast = model_ts.predict(testdata=future_df)

plt.figure(figsize=(12,6))
plt.plot(df_ts.index, df_ts['asistentes_totales'], label='Histórico', c = '#
plt.plot(future_dates, future_forecast['yhat'], label='Predicción Futura', c

#if len(future_forecast.columns) == 16:
    #plt.plot(future_dates, future_forecast['yhat_upper'], label='Upper', li
    #plt.plot(future_dates, future_forecast['yhat_lower'], label='Lower', li
    #plt.fill_between(future_dates, future_forecast['yhat'], future_forecast
    #plt.fill_between(future_dates, future_forecast['yhat'], future_forecast

#if len(future_forecast.columns) == 4:
    #plt.plot(future_dates, future_forecast['mean_ci_upper'], label='Upper',
    #plt.plot(future_dates, future_forecast['mean_ci_lower'], label='Lower',

    #plt.fill_between(future_dates, future_forecast['yhat'], future_forecast
    #plt.fill_between(future_dates, future_forecast['yhat'], future_forecast

plt.title('Predicción de Asistentes Totales Diarios Futuros')
plt.xlabel('Fecha')
plt.ylabel('Ventas')
plt.legend()
plt.grid(True)
plt.show()
```

```
Predicting using test dataframe shape = (60, 0) for ML model
For large datasets: ML predictions will take time since it has to predict ea
ch row and use that for future predictions...
    Using given input: pandas dataframe...
    Alert: No strf_time_format given for fecha. Provide strf_time format dur
ing "setup" for better results.
    converting testdata to datetime index erroring. Please check input and t
ry again.
ML predictions completed
```

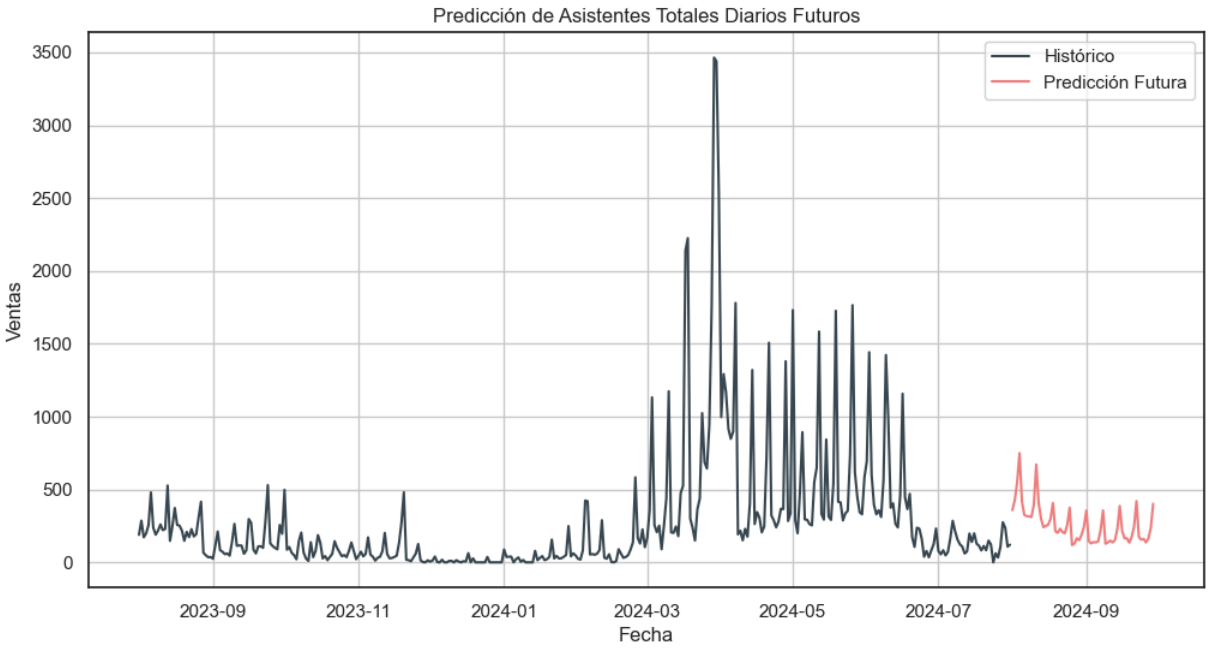

Forecast del pasado

In [62]:
```
future_periods = 60
last_date = df_ts.index[-1]
future_dates = df_ts.index

future_df = pd.DataFrame(index=future_dates)
past_forecast = model_ts.predict(testdata=future_df)

plt.figure(figsize=(12,6))
plt.plot(df_ts.index, df_ts['asistentes_totales'], label='Histórico', c = 's
plt.plot(future_dates, past_forecast['yhat'], label='Predicción Futura', c =

plt.title('Predicción de Asistentes Totales Diarios Futuros')
plt.xlabel('Fecha')
plt.ylabel('Ventas')
plt.legend()
plt.grid(True)
plt.show()
```

```
Predicting using test dataframe shape = (366, 0) for ML model
For large datasets: ML predictions will take time since it has to predict ea
ch row and use that for future predictions...
    Using given input: pandas dataframe...
    Alert: No strf_time_format given for fecha. Provide strf_time format dur
ing "setup" for better results.
ML predictions completed
```

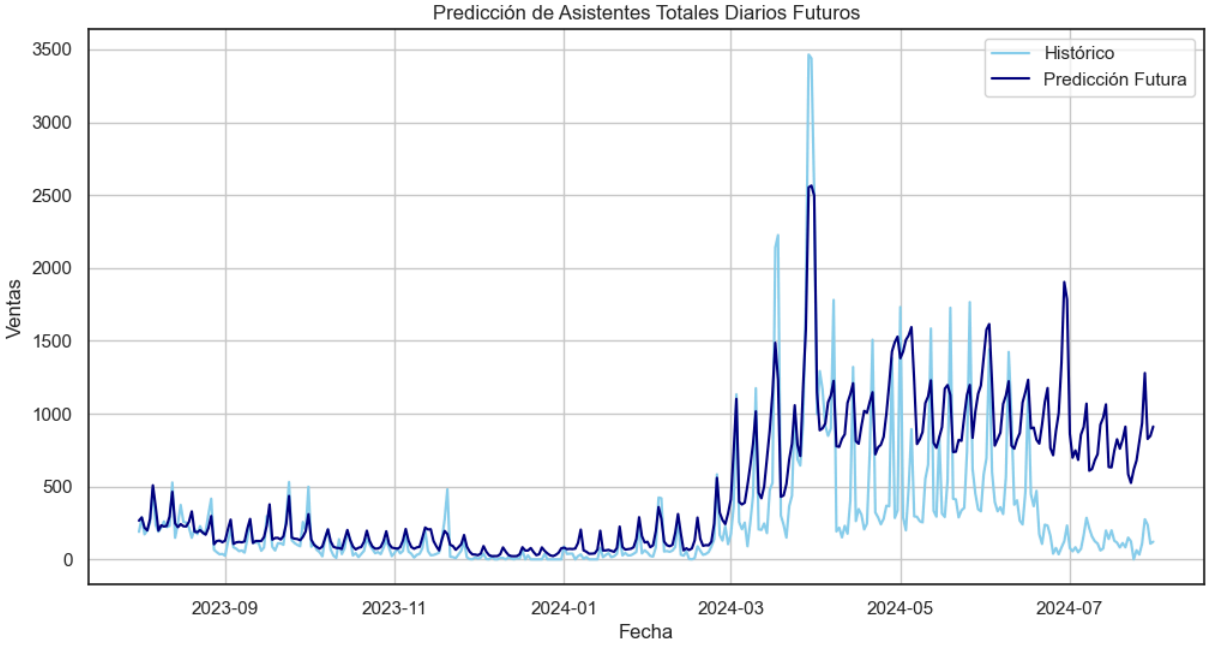

Transformación de datos a proporciones

Se hace con real/prediccion

In [63]:
```
df_proporciones = pd.DataFrame()
df_proporciones['proporcion_niños'] = df['cantidad_niños'] / df['asistentes_
df_proporciones['proporcion_adultos'] = df['cantidad_adultos'] / df['asister
df_proporciones['proporcion_alimento'] = df['alimento'] / df['ingreso_total'
df_proporciones['proporcion_extras'] = df['extras'] / df['ingreso_total']
df_proporciones['proporcion_total'] = (df_ts['asistentes_totales'] / past_fc
df_proporciones.head()
```

Out[63]:

	proporcion_niños	proporcion_adultos	proporcion_alimento	proporcion_extras	pro
0	0.206349	0.433862	0.230317	0.060398	
1	0.192308	0.534965	0.248808	0.060527	
2	0.197674	0.569767	0.289409	0.054595	
3	0.276382	0.552764	0.233494	0.062997	
4	0.149020	0.592157	0.140576	0.053917	

Método SEM

Variable latente: Satisfacción general por día.

Varoables observables:

- temperatura_promedio
- proporcion_adultos
- proporcion_niños
- proporcion_extras
- proporcion_total
- is_wknd
- is_hs

Si el p-value de alguna variable excede el 5%, esta se remueve del modelo y se repite el proceso hasta no tener variables con p-value mayor al 5%.

Definición del modelo

In [64]:
```
# Definir el modelo SEM usando la notación estándar de SEM
model_desc = """
# Latent Variables
Satisfaccion =~ temperatura_promedio + proporcion_adultos + proporcion_alime
"""
```

In [65]:
```
df_SEM = df_proporciones
df_SEM['temperatura_promedio'] = df['temperatura_promedio']
df_SEM.head()
```

Out[65]:

	proporcion_niños	proporcion_adultos	proporcion_alimento	proporcion_extras	pro
0	0.206349	0.433862	0.230317	0.060398	
1	0.192308	0.534965	0.248808	0.060527	
2	0.197674	0.569767	0.289409	0.054595	
3	0.276382	0.552764	0.233494	0.062997	
4	0.149020	0.592157	0.140576	0.053917	

Ajuste del modelo

In [66]:
```
numerical_features_SEM = ['temperatura_promedio','proporcion_adultos','propc

data_to_model_standarized_SEM = StandardScaler().fit_transform(df_SEM[numeri

data_to_model_SEM = pd.DataFrame(data_to_model_standarized_SEM,
                                 columns=numerical_features_SEM)
```

```
data_to_model_SEM['is_hs'] = df['is_hs']
```

In [67]:
```
mod = Model(model_desc)
res_opt = mod.fit(data_to_model_SEM)
estimates = mod.inspect()

# Imprimir los resultados del ajuste del modelo
estimates
```

Out[67]:

	lval	op	rval	Estimate	Std. Err	z-value
0	temperatura_promedio	~	Satisfaccion	1.000000	-	-
1	proporcion_adultos	~	Satisfaccion	-0.204914	0.07671	-2.671273
2	proporcion_alimento	~	Satisfaccion	-0.341163	0.089019	-3.832485
3	proporcion_extras	~	Satisfaccion	-0.146549	0.07312	-2.004244
4	proporcion_total	~	Satisfaccion	0.301936	0.084942	3.554615
5	is_hs	~	Satisfaccion	0.256041	0.054621	4.687599
6	Satisfaccion	~~	Satisfaccion	0.738407	0.161676	4.5672
7	is_hs	~~	is_hs	0.139787	0.014178	9.859128
8	proporcion_adultos	~~	proporcion_adultos	0.968885	0.072434	13.37616
9	proporcion_alimento	~~	proporcion_alimento	0.913817	0.070577	12.947835
10	proporcion_extras	~~	proporcion_extras	0.983976	0.073118	13.457323
11	proporcion_total	~~	proporcion_total	0.932448	0.071078	13.118662
12	temperatura_promedio	~~	temperatura_promedio	0.261667	0.146363	1.78779

Resultados del modelo

In [68]:
```
# Cargar factores estimados (cargas factoriales)
confianza_factors = [1.0, -0.204914, -0.341163, -0.146549, 0.301936, 0.25604
#proporcion_total, is_hs

# Función para calcular el valor de la variable latente
def calculate_latent_values(df):
    # Calcular Satisfaccion
    df['satisfaccion'] = (df_SEM['temperatura_promedio'] * confianza_factors
                          df_proporciones['proporcion_adultos'] * confianza_fac
                          df_proporciones['proporcion_alimento'] * confianza_fa
                          df_proporciones['proporcion_extras'] * confianza_fact
                          df_proporciones['proporcion_total'] * confianza_facto
                          df['is_hs'] * confianza_factors[5])

    return df[['satisfaccion']]
```

```
# Calcular valores latentes en el dataset
latent_values = calculate_latent_values(df)

# Mostrar los primeros valores calculados
latent_values['fecha'] = df['fecha']
latent_values.head()
```

Out[68]:

	satisfaccion	fecha
0	22.038413	2023-08-01
1	24.096444	2023-08-02
2	22.015635	2023-08-03
3	21.100454	2023-08-04
4	22.099115	2023-08-05

In [69]:

```
sns.histplot(
    data=latent_values['satisfaccion'],
    bins=50,
    kde=True,  # Añade la curva de densidad
    color='#546873'
)

sat_mean = latent_values['satisfaccion'].mean()

plt.title('Distribución de Satisfacción')
plt.xlabel('Nivel de Satisfacción')
plt.ylabel('Frecuencia')

plt.axvline(sat_mean, color='lightcoral', linestyle='--', label=f'Media: {sa
plt.legend()

plt.grid(True, alpha=0.4)
plt.show()
```

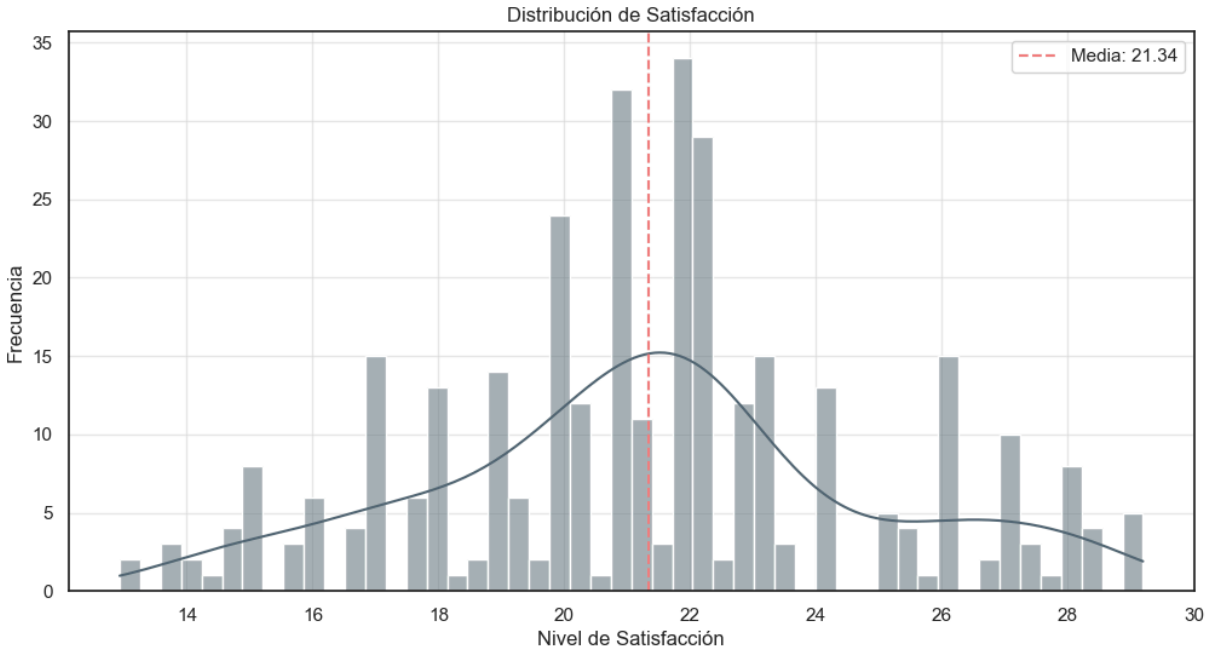

In [70]:
```
plt.plot(latent_values['fecha'],latent_values['satisfaccion'], c = '#3b4a52'

plt.title('Evolución de la Satisfacción en el Tiempo')
plt.xlabel('Fecha')
plt.ylabel('Nivel de Satisfacción')
plt.grid()
```

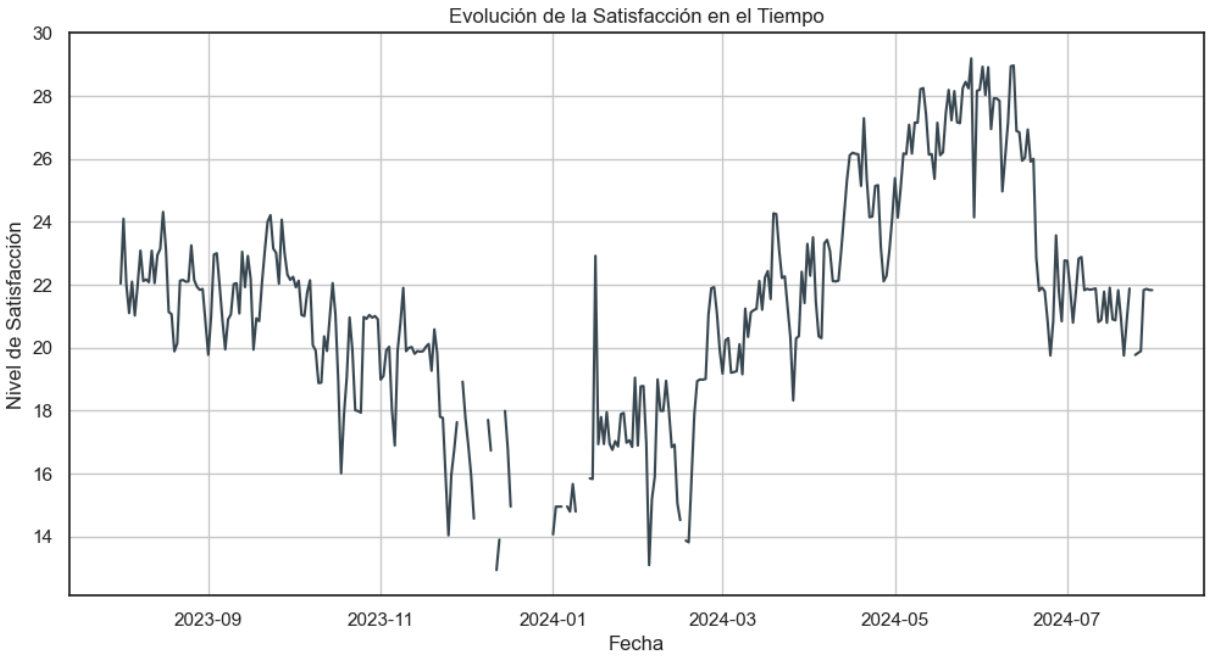

Visualización del modelo

In [71]:
```
sm = semplot(mod, 'modelo_sem.png', engine = 'dot')
sm
```

Out[71]:

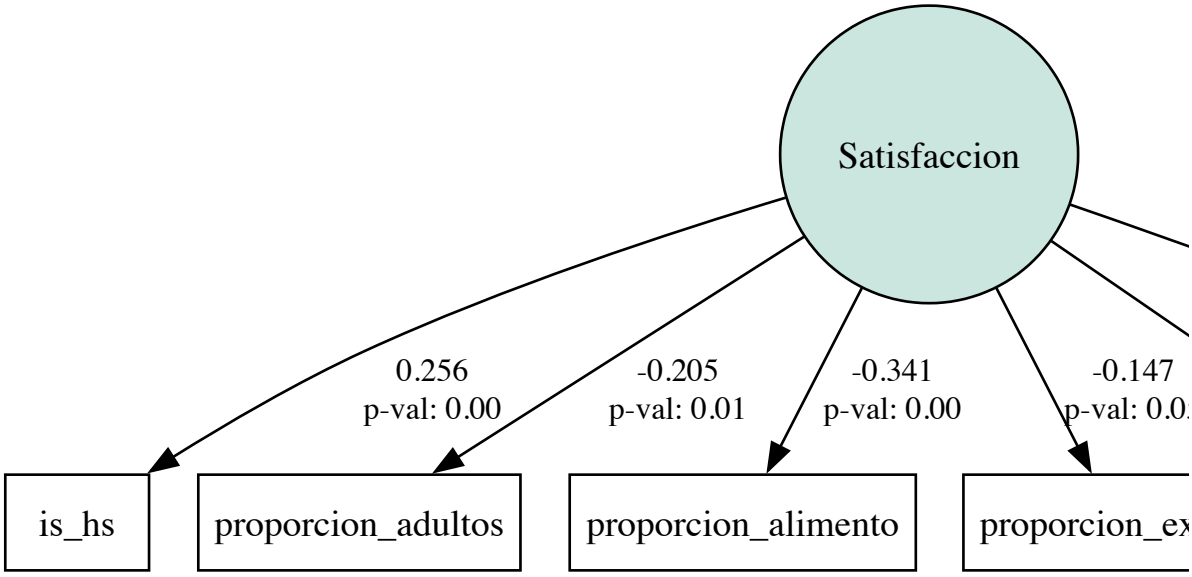

Análisis del modelo

Las variables seleccionadas, tras eliminar aquellas cuyo valor de p-value superaba 0.05, fueron: la temperatura promedio del día, la proporción de adultos respecto al total de visitantes, la proporción de compras adicionales en relación con los ingresos totales, la proporción de visitantes reales en comparación con los esperados y si era temporada alta o no. De estas, se tomó la temperatura promedio como la variable de referencia, asignándole un valor de 1, a partir del cual se compararon las demás.

Las tres variables que más influyeron en la satisfacción general diaria fueron: la temperatura promedio (valor de 1), seguida por la proporción total de asistentes reales contra los esperados(valor de 0.30) y, por último, si era temporada alta (valor de 0.26). También podemos notar que la proporción de adultos, de alimentos y de consumos extra tienen coeficiente negativo, por lo que si esta proporción crece, la satisfacción del día disminuye.

El impacto de estas variables en la satisfacción general se interpreta en función de cuánto afecta la variación de cada una en la ecuación final del modelo. Es decir, un cambio en alguna de estas variables tiene un efecto proporcional en la satisfacción general, según los valores estimados.

Además en la gráfica de la satisfacción en el tiempo se pueden apreciar huecos, estos correponden a los días que el parque recibió 0 visitantes, por lo que el modelo no puede calcular la satisfacción los días que no va nadie, lo cual hace sentido pues si no van personas al parque no hay una satisfacción que medir.

Recomendaciones A/B testing

Recomendamos a la empresa comenzar a implementar marketing digital como Google y Facebook ads, de forma más recurrente y profesional, para que de esta manera se puedan utilizar los datos recopilados. Una vez teniendo los datos disponibles, tener la posibilidad de hacer pruebas de a/b testing.

Recomendaciones de uso de AI

En la página web del parque acuático, implementar un chat bot que ayude a responder preguntas frecuentes sobre el parque a los posibles visitantes. Por ejemplo, que informe sobre la comida que se vende, si abre en días festivos, si hay eventos especiales, qué atracciones ofrece, y recomendaciones generales dependiendo de lo que las personas pregunten.

Propuestas y recomendaciones

A partir de los datos obtenidos, se puede notar que los meses de marzo, abril y mayo conforman la temporada más alta del parque. Dado que el objetivo es aumentar la cantidad de visitantes, previo a marzo y sus inicios, se propone hacer campañas de marketing más fuertes, con un enfoque en épocas de calor y semana santa.

Otro aspecto de importancia observado a partir del análisis de los datos, es que el fin de semana es el momento en el que más personas visitan el parque. Debido a esto, proponemos que en estos días se realicen eventos familiares, como actividades con temáticas enfocadas para los niños, días musicales, días de espuma, etc. De esta manera, no solo se busca adquirir nuevos visitantes, sino que también se logra que los visitantes vuelvan más veces, aumentando el número de asistentes generales del parque acuático.

La recomendación para la empresa es que seleccione dos de sus albercas con las mismas características, es decir, del mismo tamaño y profundidad, ubicadas una junto a la otra, y que la única diferencia entre ellas sea que una cuente con calefacción y la otra no. Para que el experimento sea efectivo, será necesario asignar a un empleado en cada alberca que registre la hora de entrada y salida de los visitantes, escaneando un código que se encontrará en el brazalete de cada uno de ellos. Esto permitirá recopilar datos precisos sobre cuál de las albercas retiene a los visitantes por más tiempo, proporcionando información clave para evaluar el impacto de la calefacción en la preferencia y comportamiento de los visitantes.

Created with Jupyter by Luis Márquez, Ana Sofía Hinojosa, and Ivanna Herrera